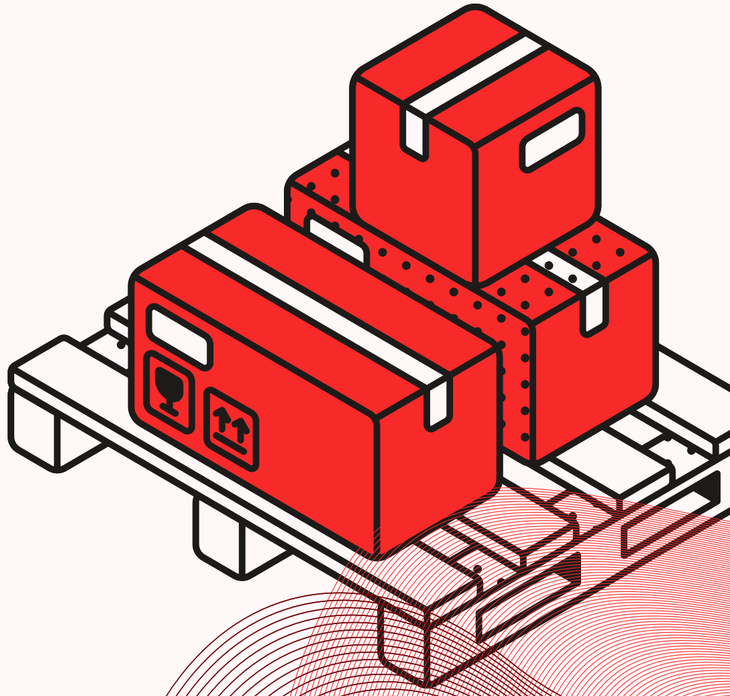
HUTECH
Đại học Công nghệ Tp.HCM

KHOA CÔNG NGHỆ THÔNG TIN

MÁY HỌC THỐNG KÊ

ĐỒ ÁN MÔN HỌC
Ứng Dụng Các Thuật Toán Vào Trong Dữ liệu Kinh Tế



SINH VIÊN THỰC HIỆN

1. NGUYỄN ĐĂNG KHOA
2. VÕ THỊ NGỌC HIỀN
3. NGUYỄN ĐỨC VINH
4. PHAN XUÂN DƯƠNG

BỘ DỮ LIỆU



25.000 đơn đặt hàng từ 8.000 khách hàng trên 20 quốc gia và 14 danh mục sản phẩm — với đầy đủ lịch sử mua hàng, nhãn khách hàng rời bỏ, tín hiệu RFM, dữ liệu phiên và xu hướng doanh thu hàng tháng

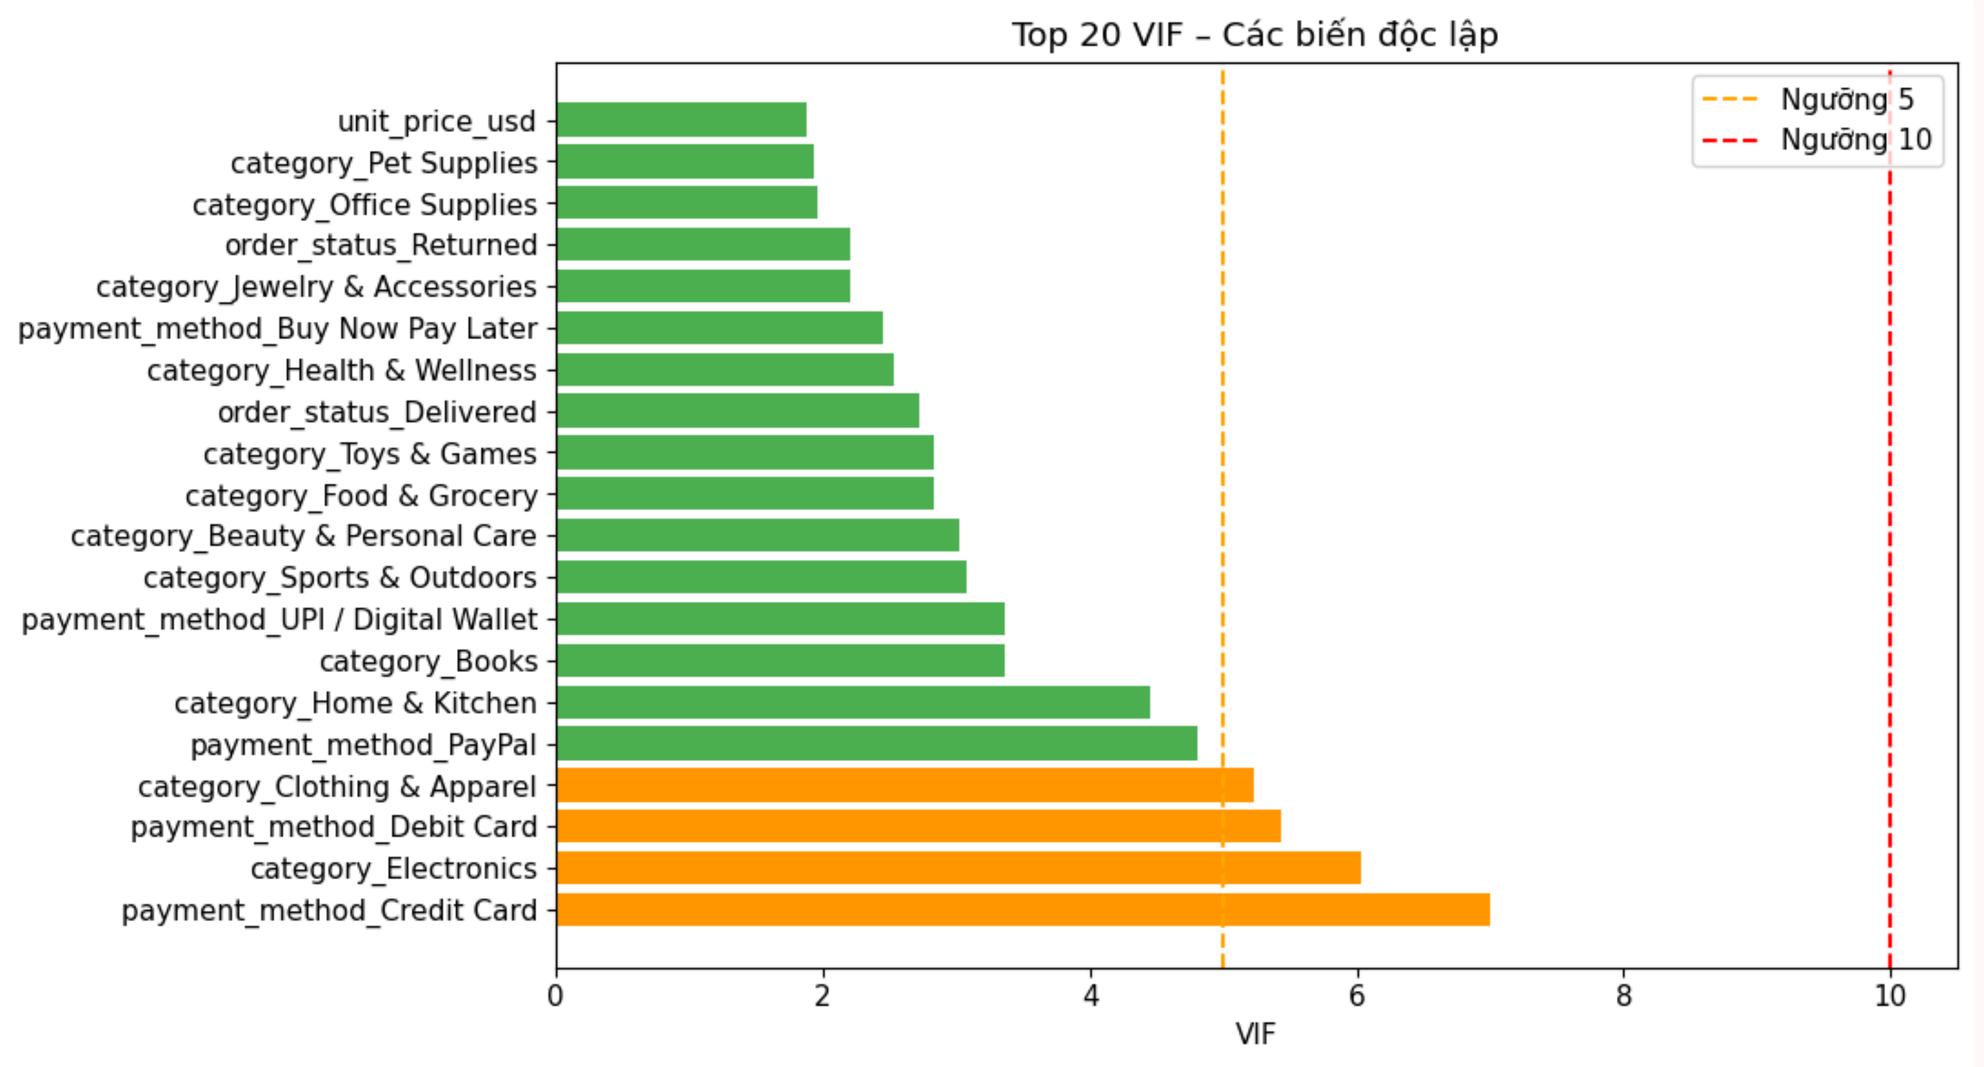
order_id	Mã định danh đơn hàng
customer_id	Mã định danh khách hàng
order_date	Ngày đặt hàng
year	Năm đặt hàng
month	Tháng đặt hàng
quarter	Quý trong năm
day_of_week	Thứ trong tuần
product_name	Tên sản phẩm
category	Nhóm sản phẩm

unit_price_usd	Giá bán một đơn vị sản phẩm
unit_price_usd	Số lượng sản phẩm
unit_price_usd	Tổng tiền trước giảm giá, phí vận chuyển và thuế
unit_price_usd	Tỷ lệ giảm giá
unit_price_usd	Số tiền được giảm
unit_price_usd	Phí vận chuyển
unit_price_usd	Số tiền thuế
unit_price_usd	Tổng giá trị đơn hàng (Biến mục tiêu dùng làm đầu vào mô hình sau khi nén theo tuần)

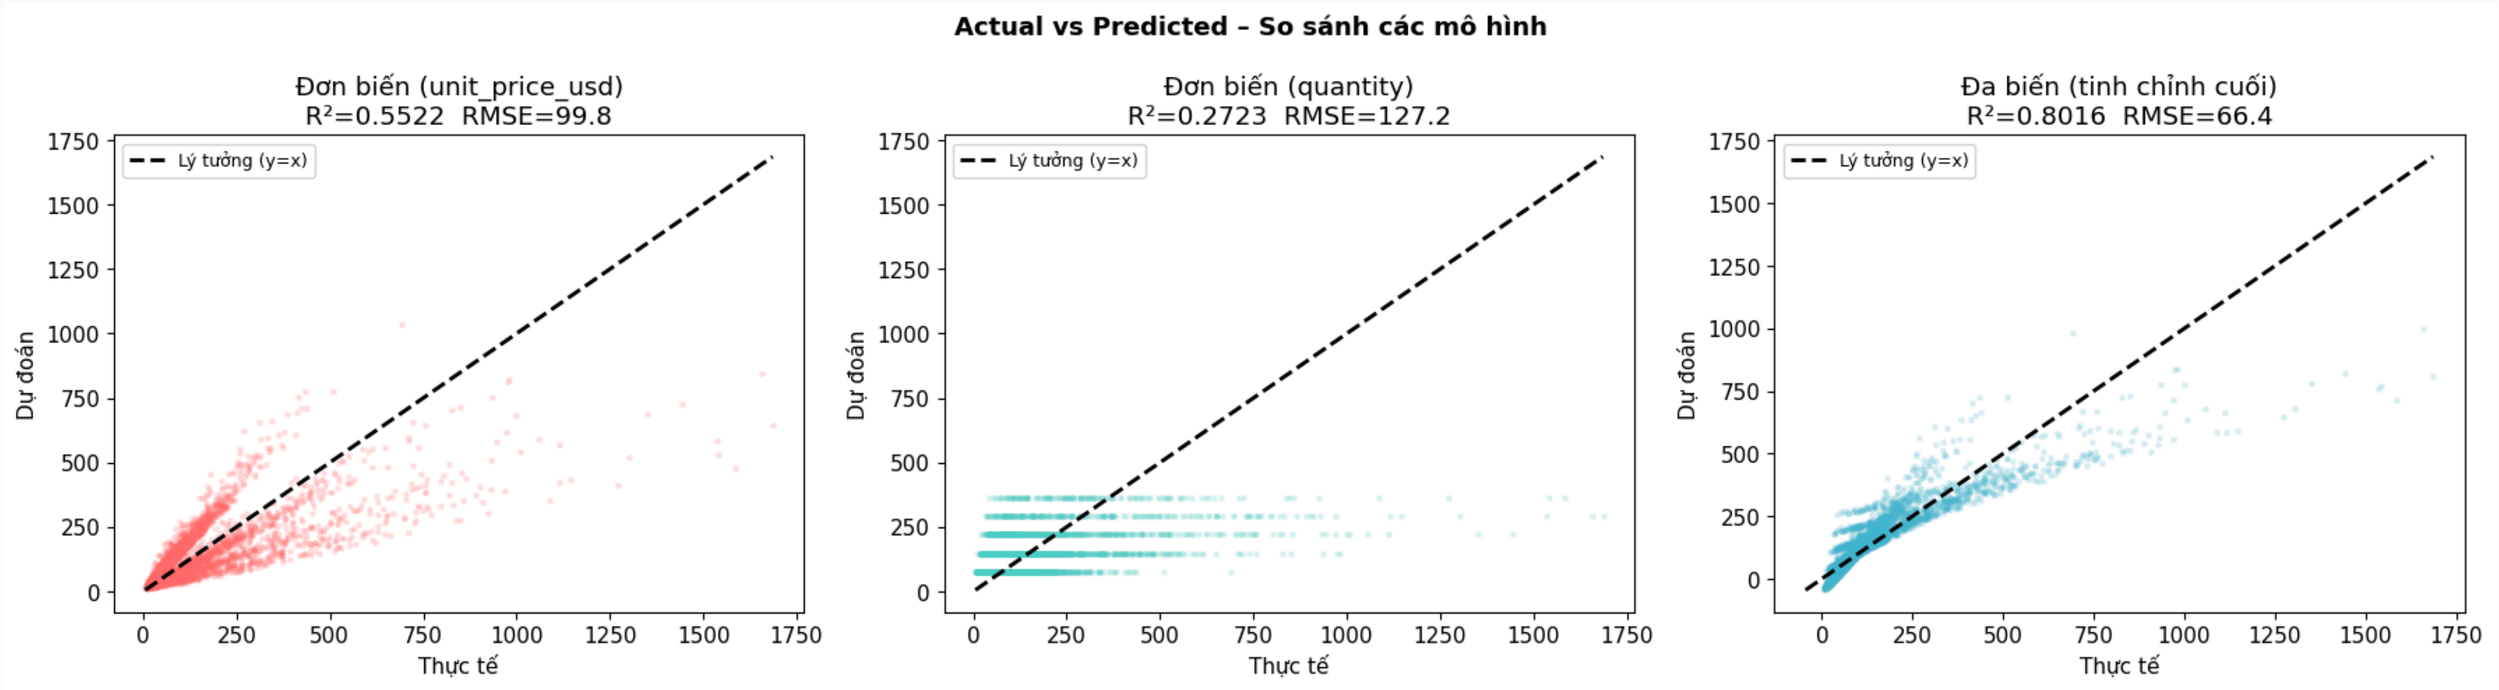
payment_method	Phương thức thanh toán
device_used	Thiết bị được dùng khi mua hàng
delivery_days	Số ngày giao hàng
order_status	Trạng thái đơn hàng
returned	Cho biết đơn hàng có bị hoàn trả hay không
customer_rating	Điểm đánh giá của khách hàng
session_duration_minutes	Thời lượng phiên mua hàng
pages_viewed_before_purchase	Số trang đã xem trước khi mua
is_repeat_customer	Cho biết khách hàng có phải khách hàng quay lại hay không



MÔ HÌNH HỒI QUY TUYẾN TÍNH



MÔ HÌNH HỒI QUY TUYẾN TÍNH



MÔ HÌNH HỒI QUY TUYẾN TÍNH

Mô Hình	Số Biến	R^2	RMSE
Đơn biến unit_price_usd	1	552.165	99.822.007
Đơn biến quantity	1	272.317	127.244.271
Đa biến đầy đủ	41	801.604	66.440.529
Đa biến tinh chỉnh	5	801.588	66.443.365



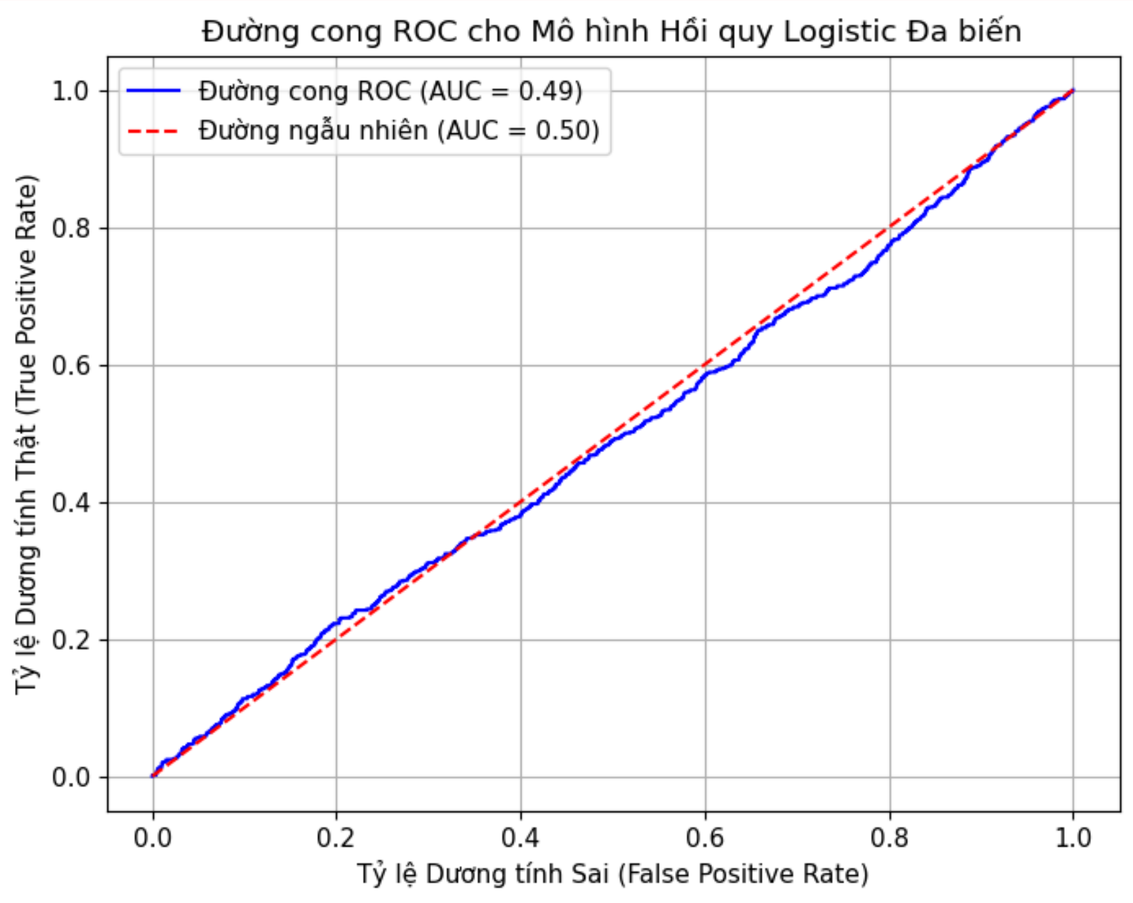
MÔ HÌNH HỒI QUY LOGISTIC

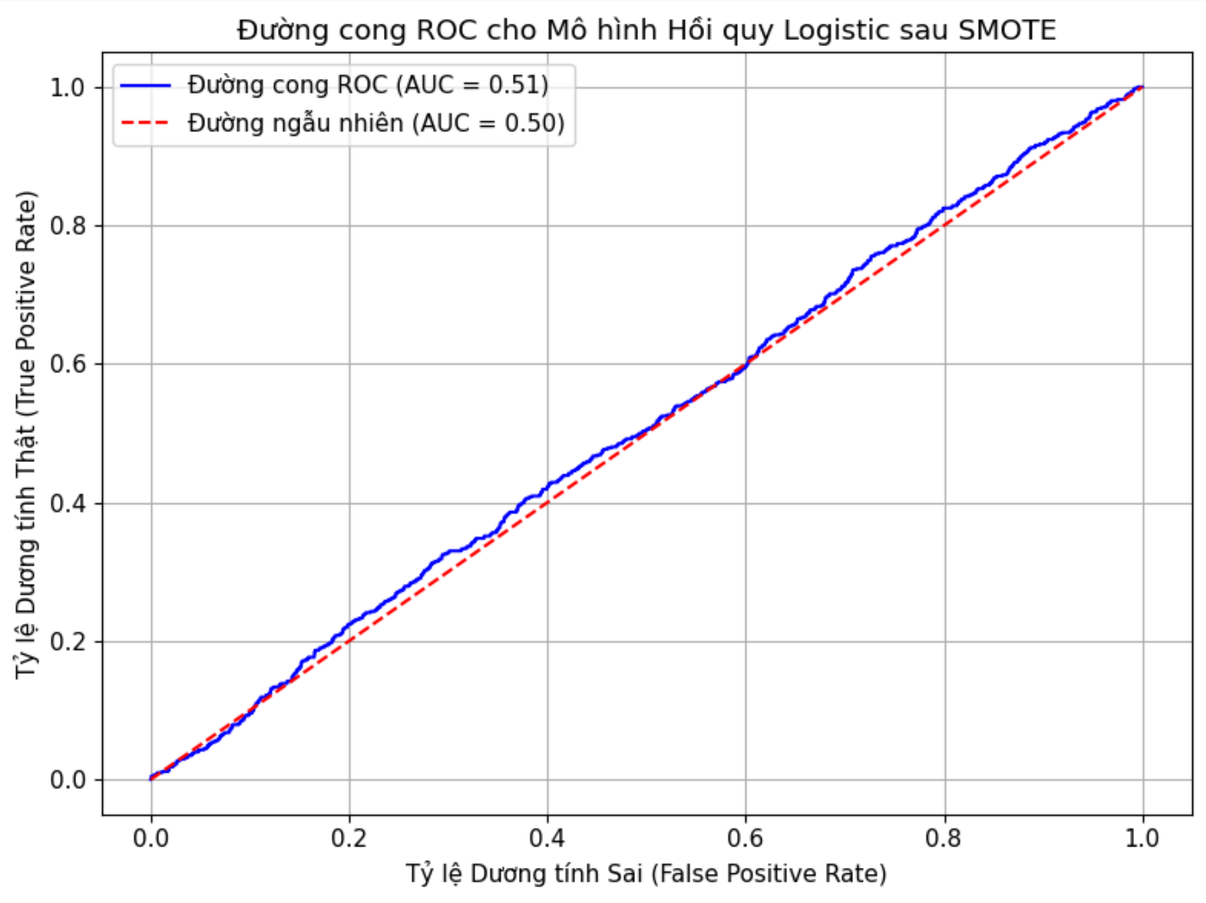
Tên Mô Hình	Độ chính xác (Accuracy)	Ma trận nhầm lẫn (Confusion Matrix)	Macro Avg (Precision / Recall / F1)	Weighted Avg (Precision / Recall / F1)
Biến liên tục *(total_amount_usd)*	9.173	[[6880, 0], [620, 0]]	0.46 / 0.50 / 0.48	0.84 / 0.92 / 0.88
Biến nhị phân *(gender_binary)*	9.173	[[6880, 0], [620, 0]]	0.46 / 0.50 / 0.48	0.84 / 0.92 / 0.88
Biến danh định *(payment_method)*	9.173	[[6880, 0], [620, 0]]	0.46 / 0.50 / 0.48	0.84 / 0.92 / 0.88
Biến thứ bậc *(membership_tier)*	9.173	[[6880, 0], [620, 0]]	0.46 / 0.50 / 0.48	0.84 / 0.92 / 0.88
Mô hình đa biến *(Kết hợp tất cả)*	9.173	[[6880, 0], [620, 0]]	0.46 / 0.50 / 0.48	0.84 / 0.92 / 0.88

MÔ HÌNH HỒI QUY LOGISTIC

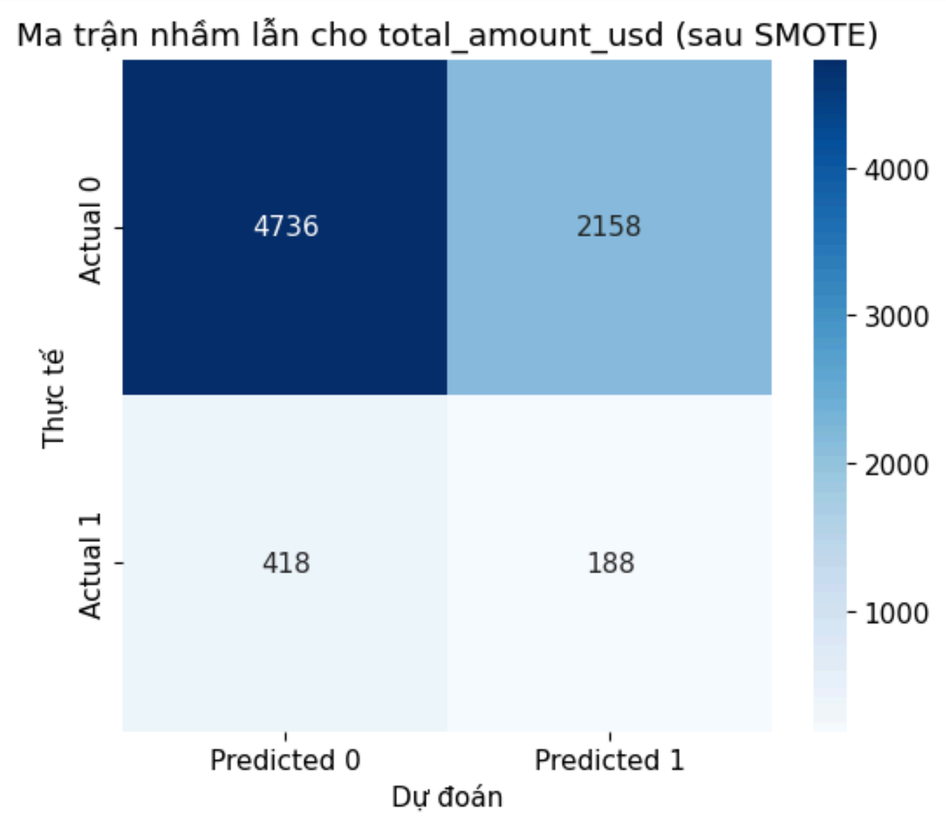
Tên Mô Hình	Độ chính xác (Accuracy)	Ma trận nhầm lẫn (Confusion Matrix)	Macro Avg (Precision / Recall / F1)	Weighted Avg (Precision / Recall / F1)
Biến liên tục *(total_amount_usd)*	6.565	[[4736, 2158], [418, 188]]	0.50 / 0.50 / 0.46	0.85 / 0.66 / 0.73
Biến nhị phân *(gender_binary)*	4.956	[[3411, 3483], [300, 306]]	0.50 / 0.50 / 0.39	0.85 / 0.50 / 0.60
Biến danh định *(payment_method)*	8.869	[[6631, 263], [585, 21]]	0.50 / 0.50 / 0.49	0.85 / 0.89 / 0.87
Biến thứ bậc *(membership_tier)*	4.572	[[3077, 3817], [254, 352]]	0.50 / 0.51 / 0.37	0.86 / 0.46 / 0.57
Mô hình đa biến *(Kết hợp tất cả)*	8.019	[[5928, 966], [520, 86]]	0.50 / 0.50 / 0.50	0.85 / 0.80 / 0.83

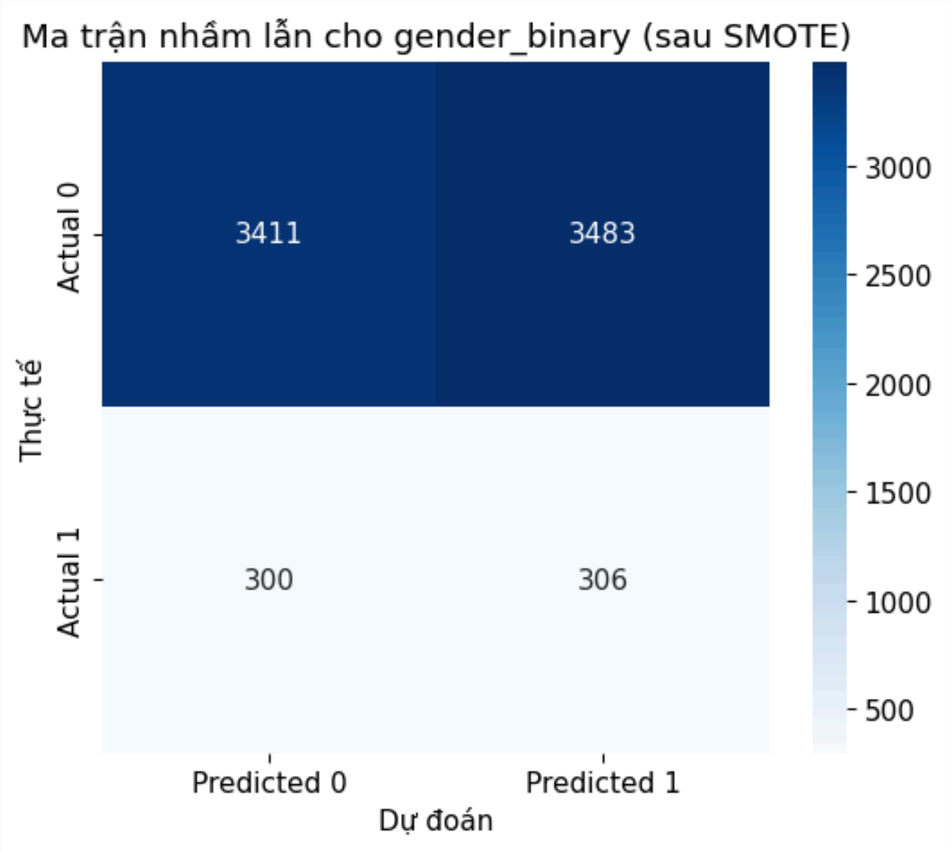
MÔ HÌNH HỒI QUY LOGISTIC



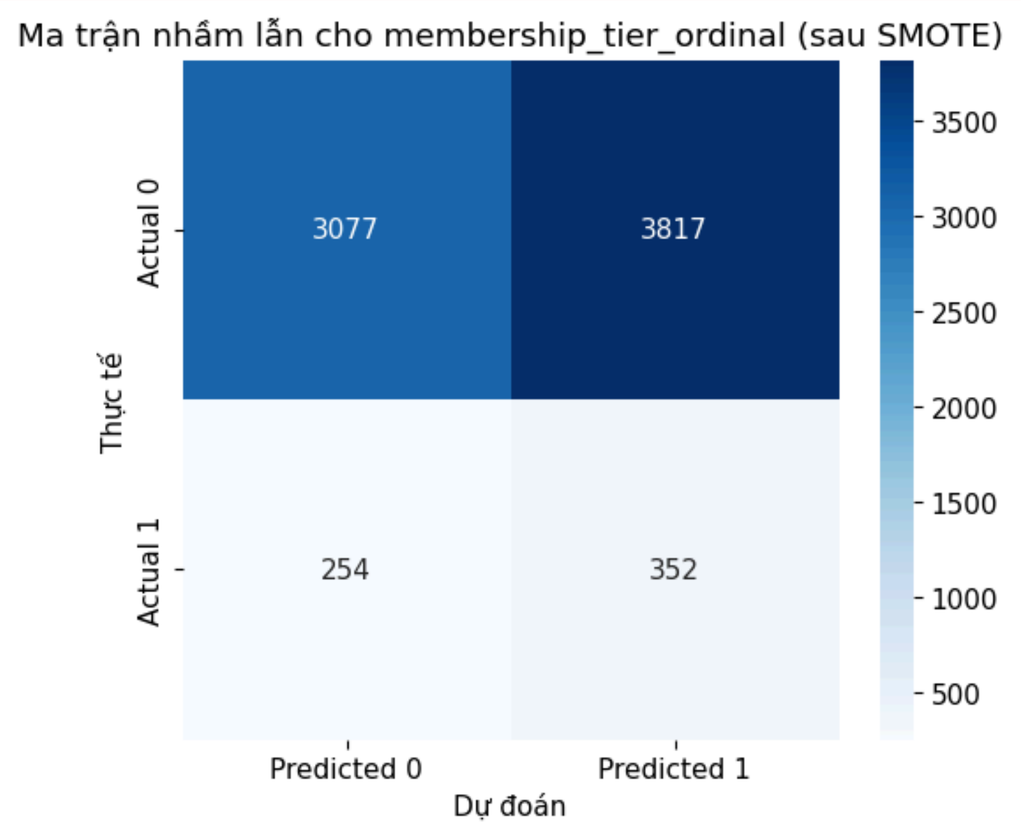


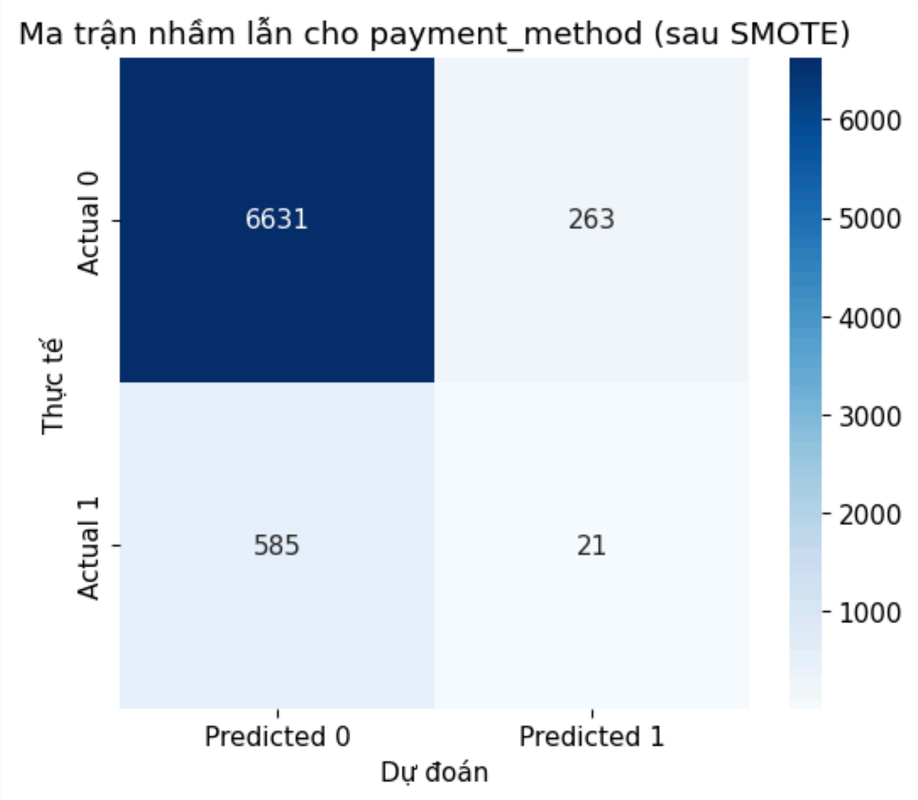
MÔ HÌNH HỒI QUY LOGISTIC





MÔ HÌNH HỒI QUY LOGISTIC





QUY TRÌNH THỰC NGHIỆM

Quy trình tiền xử lý dữ liệu

1 Xử lý ngoại lai

IQR Clipping: giới hạn giá trị ngoài [Q1-1.5×IQR, Q3+1.5×IQR]

2 Tạo biến mới

customer_tenure_days = max(registration_date) − registration_date

3 Chuẩn hóa biến số

StandardScaler: z = (x − μ) / σ

4 Mã hóa phân loại

OneHotEncoder, handle_unknown='ignore'

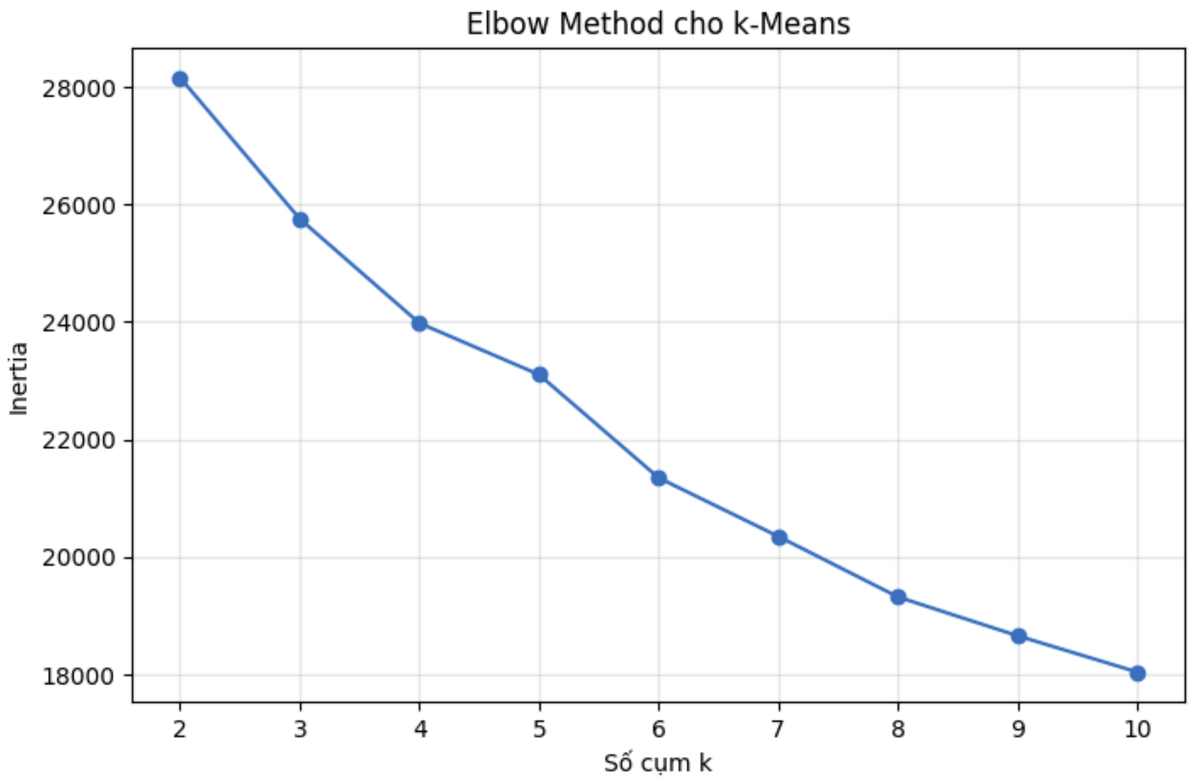
5 Chọn biến mô hình

18 biến đầu vào; loại customer_id, registration_date, churned

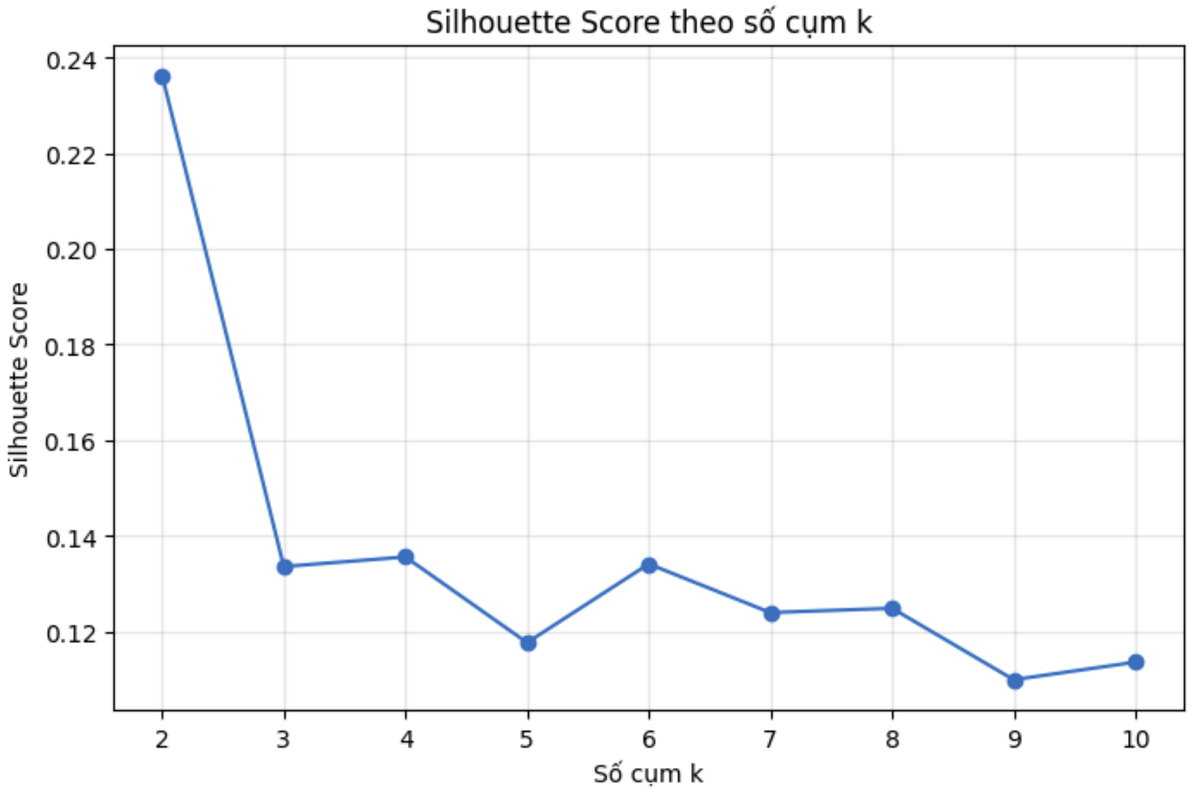
6 Giảm chiều

PCA: 10 thành phần cho mô hình (≥80% phương sai), 2 thành phần để trực quan hóa

Phương pháp chọn K tối ưu K-mean



Silhouette Score theo K



Elbow Method: Inertia giảm theo K

Kết quả Phân Cụm

Cụm 0 — Khách hàng giá trị cao

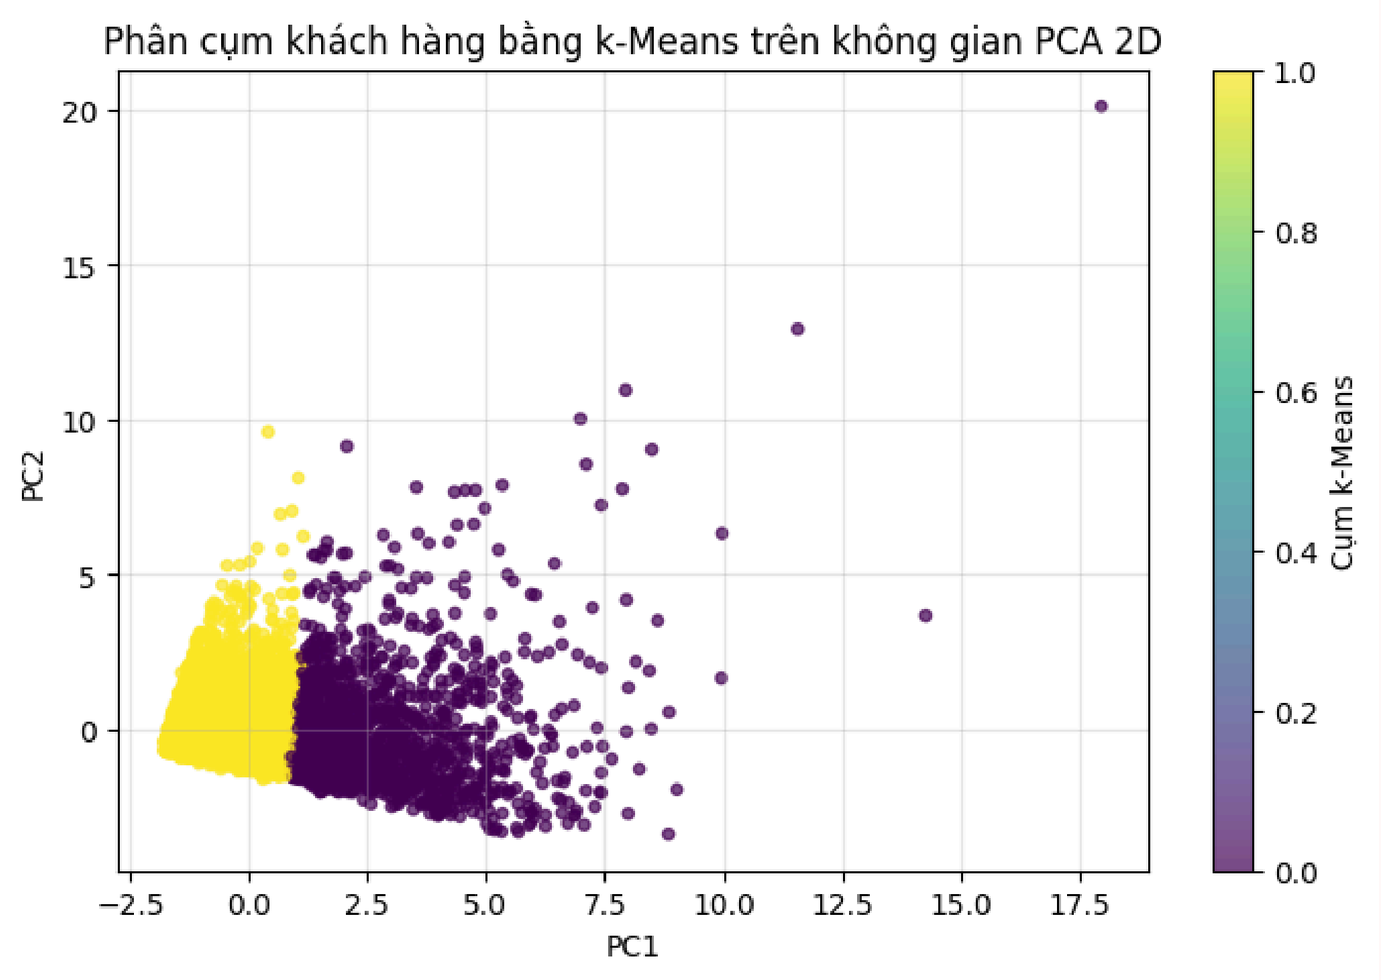
1.748 khách hàng (21,9%)

Tổng đơn hàng TB	**38,30**
Tổng chi tiêu TB (USD)	**4.027,02**
Giá trị đơn TB (USD)	**114,28**
Ngày từ lần mua gần nhất	**57,80**
Tỉ lệ churn	**6%**

Cụm 1 — Khách hàng phổ thông

6.252 khách hàng (78,1%)

Tổng đơn hàng TB	**10,46**
Tổng chi tiêu TB (USD)	**868,51**
Giá trị đơn TB (USD)	**89,41**
Ngày từ lần mua gần nhất	**60,08**
Tỉ lệ churn	**10%**



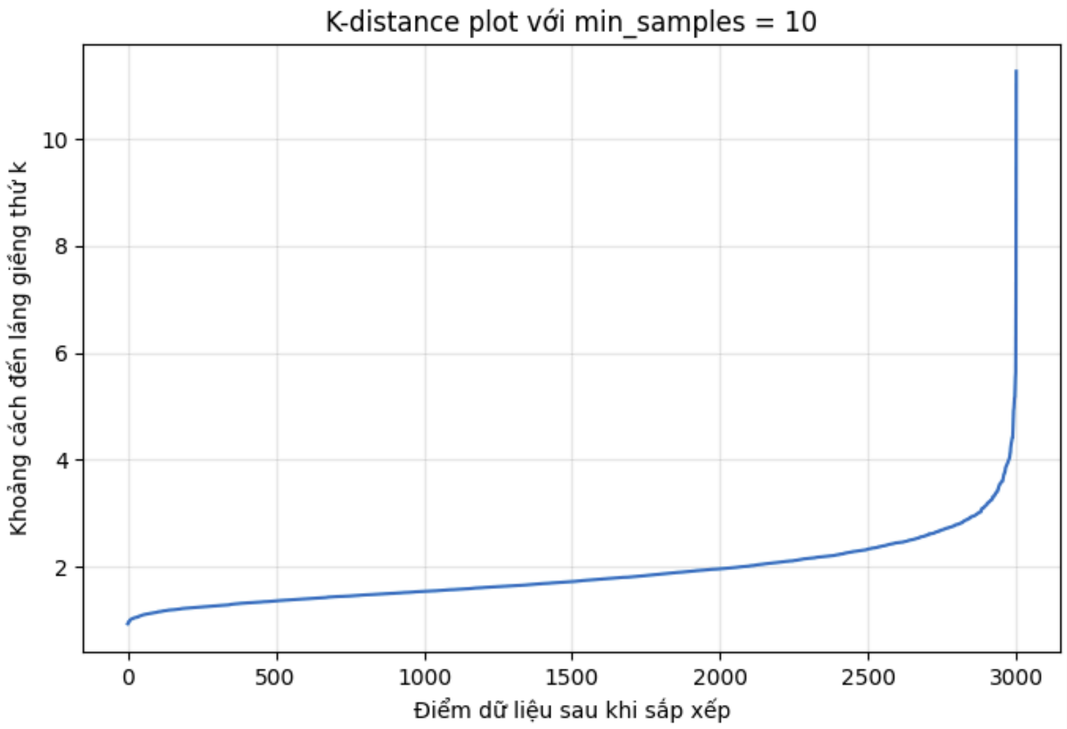
Hai cụm tách biệt rõ trên không gian PCA 2D, phản ánh sự khác biệt có ý nghĩa về hành vi tiêu dùng giữa hai nhóm khách hàng.

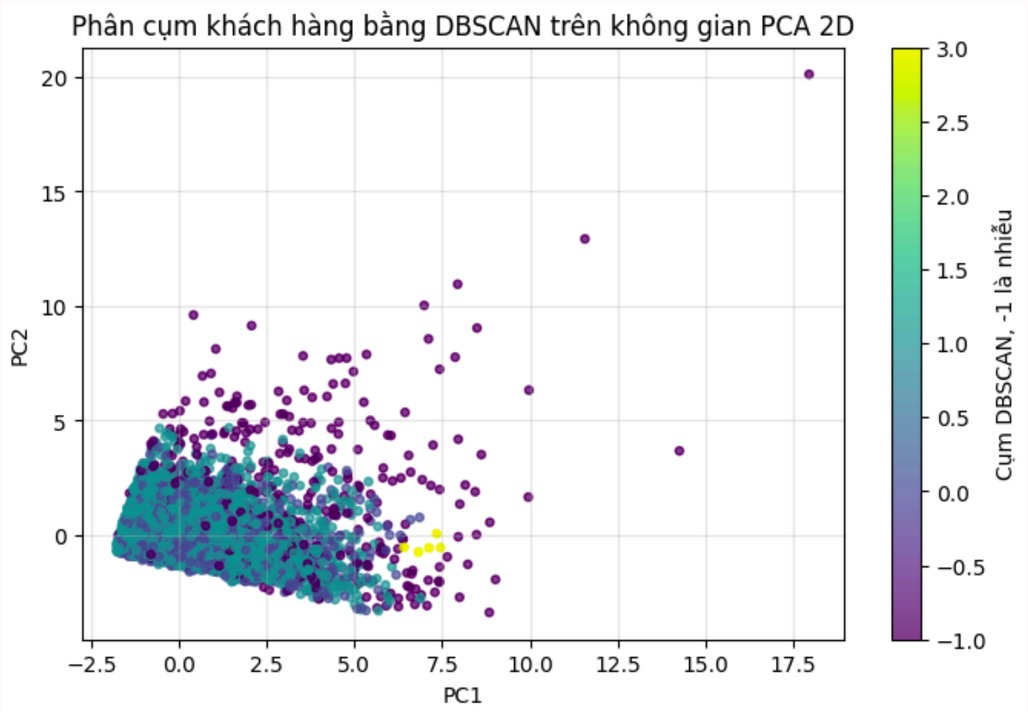
Phân cụm DBSCAN

Tham số DBSCAN tối ưu

ε (epsilon) tối ưu	2.018
min_samples tối ưu	5

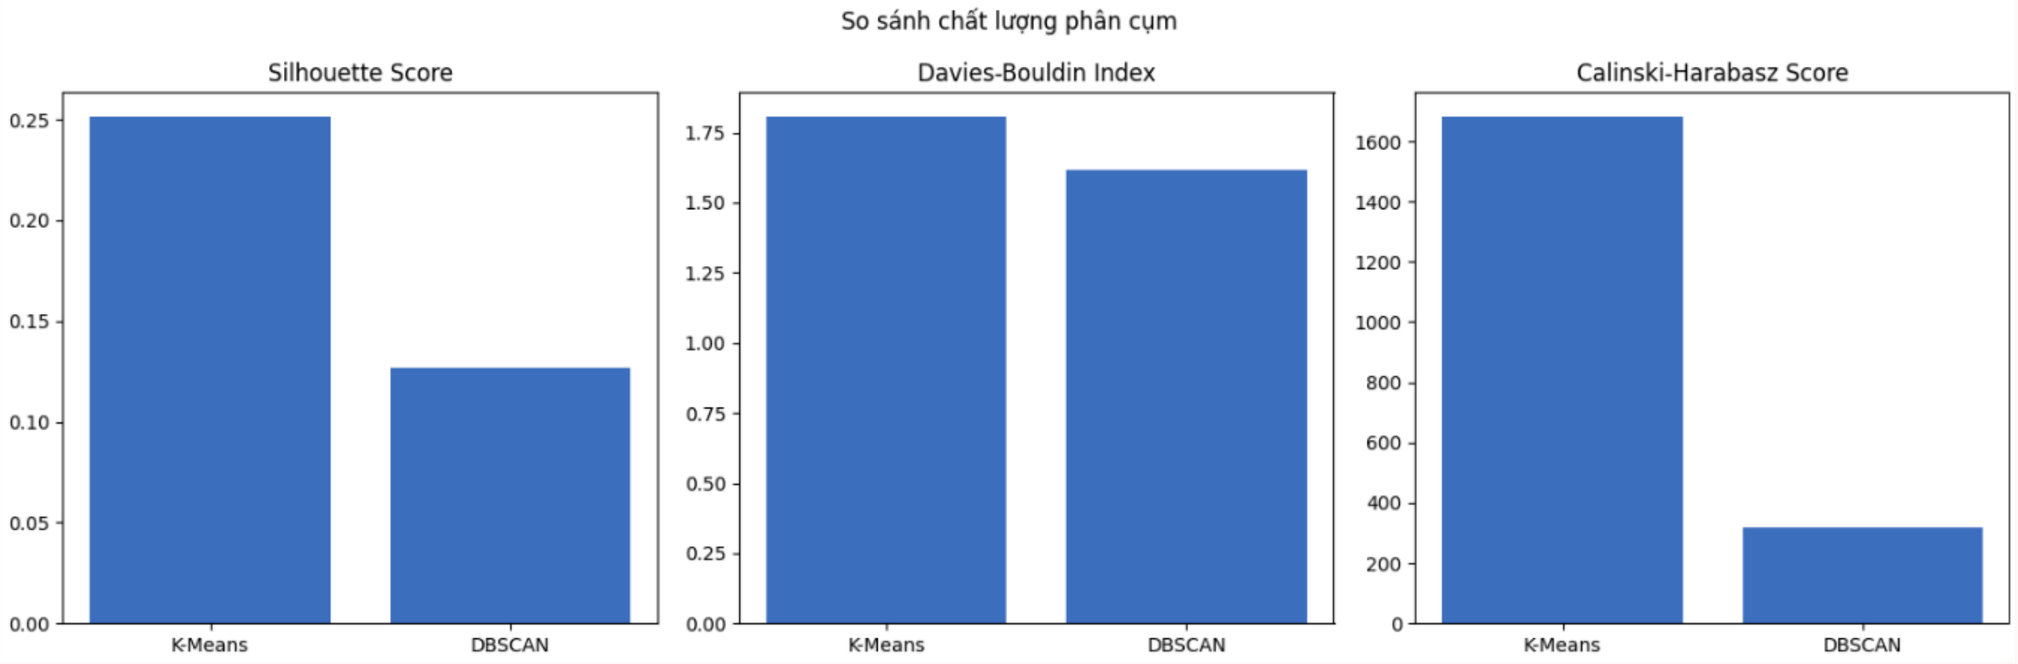
Số cụm phát hiện	4
Silhouette Score	0.131
Tỉ lệ điểm nhiễu	10,27%



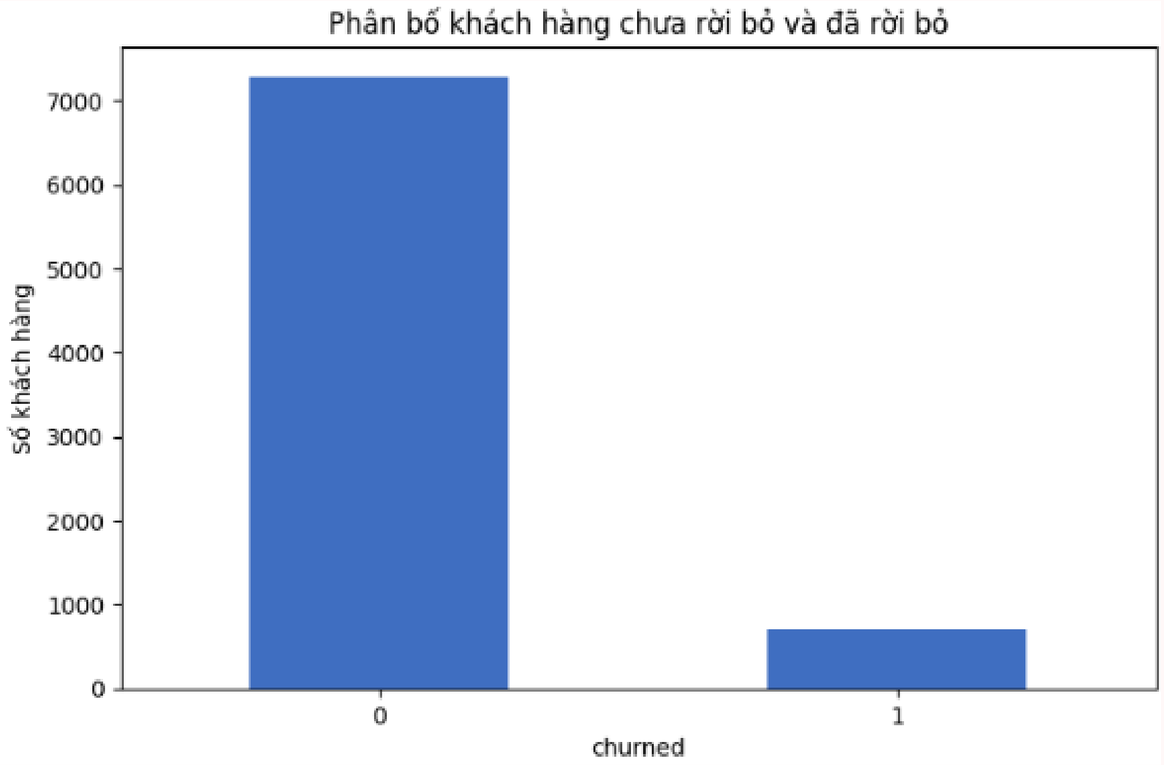


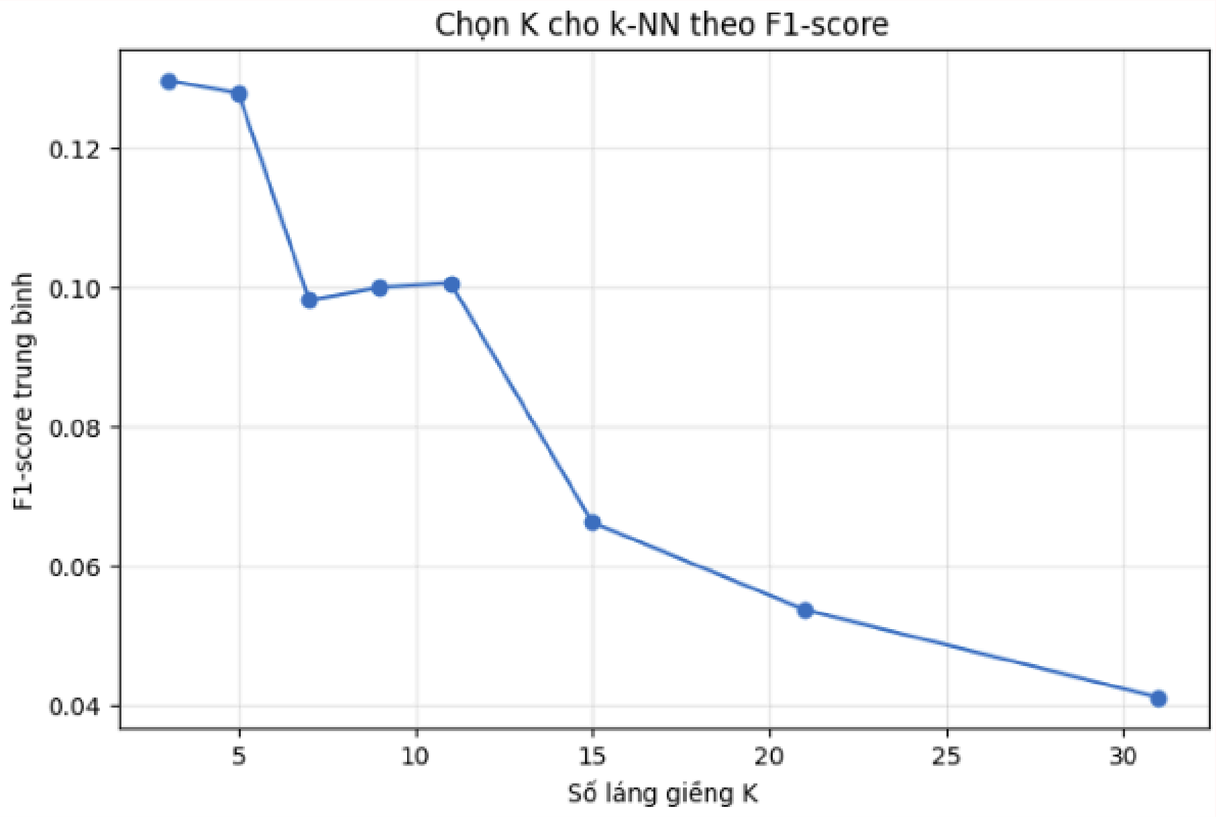
So sánh chỉ số đánh giá K-mean DBSCAN

Chỉ số	K-Means	DBSCAN
Số cụm	2	4
Silhouette Score	**0.251**	0.131
Davies-Bouldin Index	1.804	**1.615**
Calinski-Harabasz	**1679,9**	319,2
Tỉ lệ điểm nhiễu	**0%**	5,72%



Chọn K tối Ưu cho K_nn



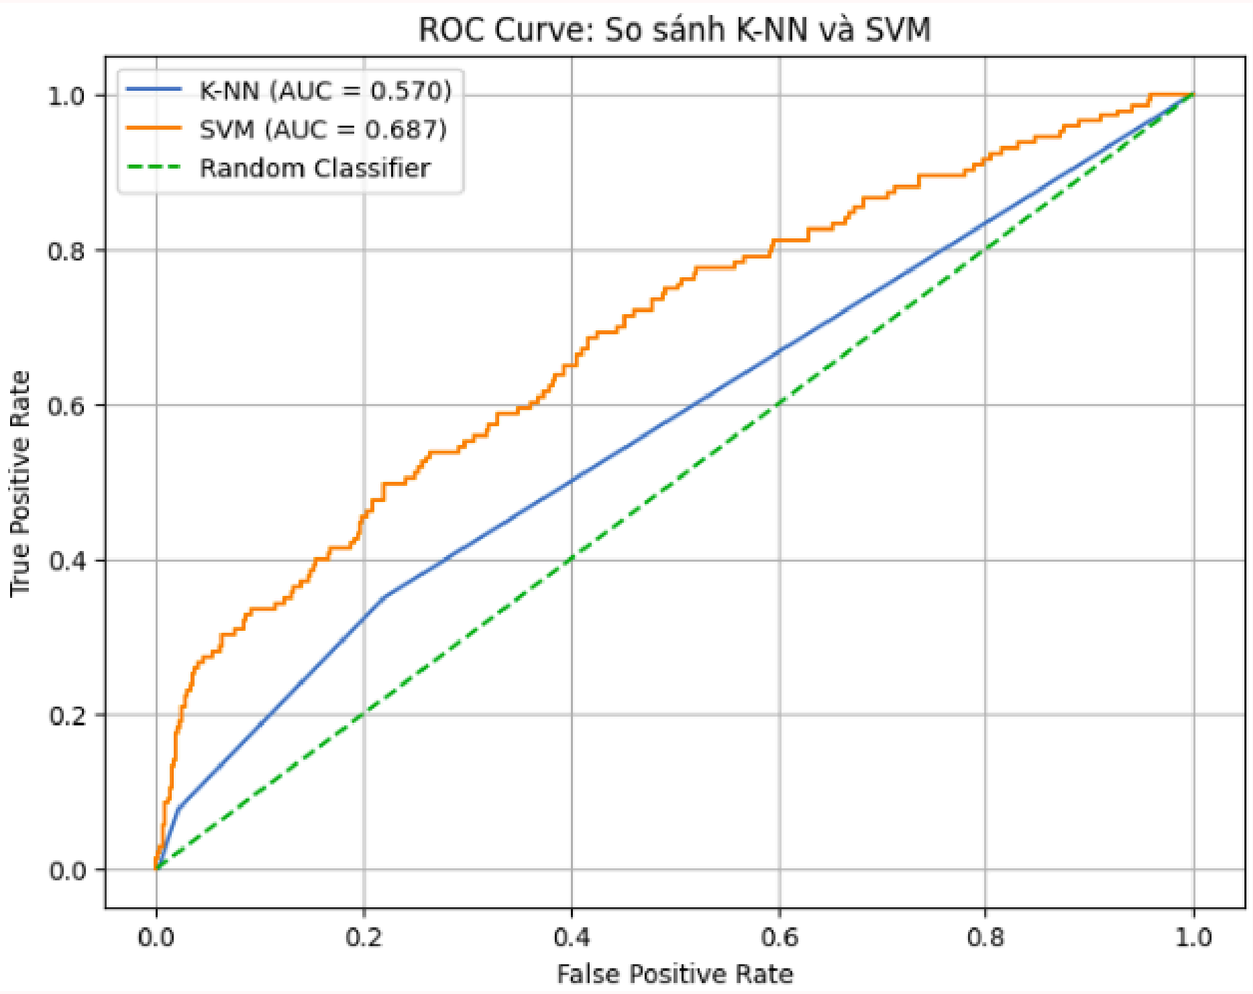


Hình F1-Score theo K trong K-NN

KẾT QUẢ THỰC NGHIỆM

Kết quả phân lớp: K-NN và SVM

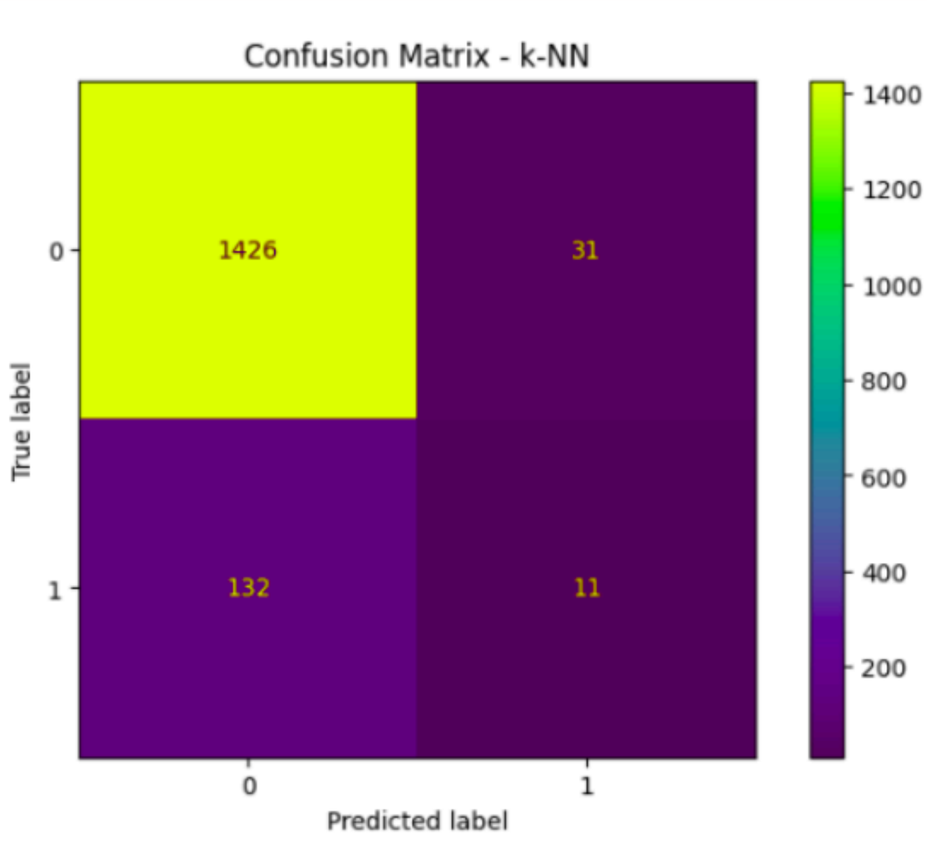
Chỉ số	K-NN (K=3)	SVM	Tốt hơn
Accuracy	**0.900**	0.660	K-NN
Precision (churn)	**0.260**	0.150	K-NN
Recall (churn)	0.080	**0.590**	SVM
F1-Score (churn)	0.130	**0.230**	SVM
ROC-AUC	0.570	**0.687**	SVM
Tốc độ dự báo	Chậm O(n)	**Nhanh O(d)**	SVM



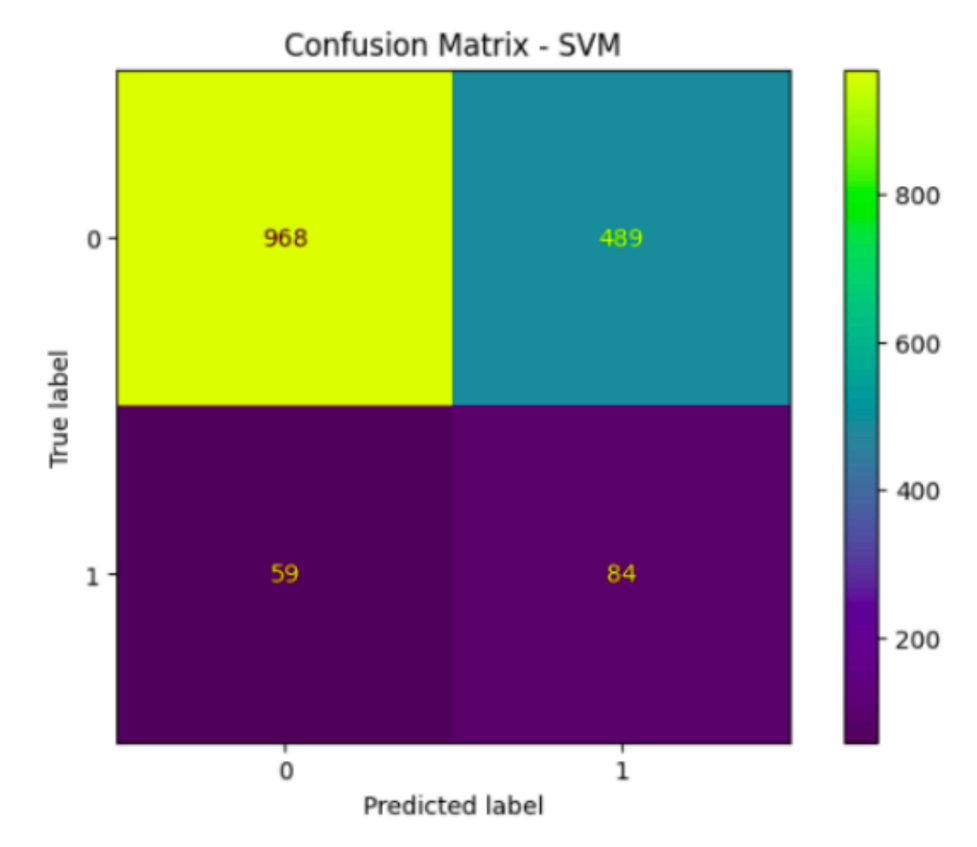
Do dữ liệu lệch lớp, F1/Recall của lớp churn quan trọng hơn Accuracy. SVM (class_weight='balanced') phát hiện churn tốt hơn (Recall 0.59 so với 0.08), trong khi K-NN có Accuracy và độ giải thích cao hơn.

KẾT QUẢ THỰC NGHIỆM

Kết quả phân lớp: K-NN và SVM



Confusion Matrix của K-NN trên tập test



Confusion Matrix của SVM trên tập test

GIỚI THIỆU BÀI TOÁN

Khách hàng rời bỏ (Customer Churn) là hiện tượng khách hàng ngừng sử dụng sản phẩm, dịch vụ hoặc chấm dứt giao dịch với doanh nghiệp.

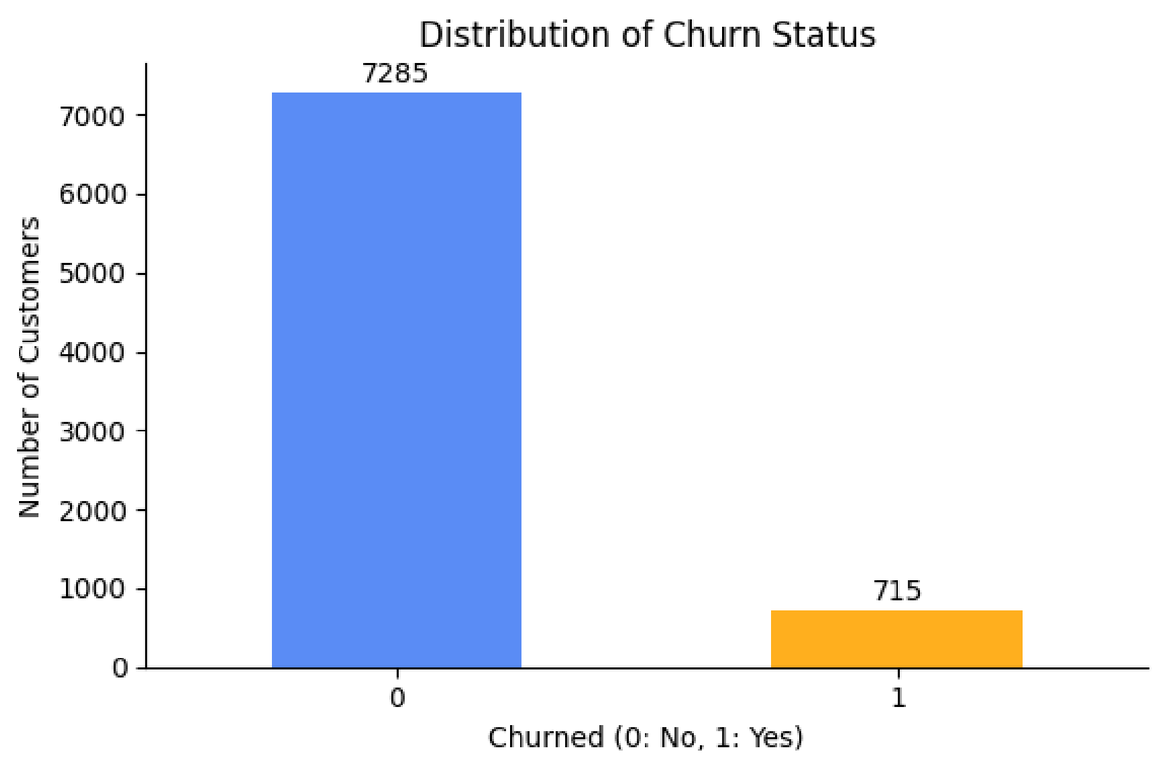
- **Churn chủ động (Voluntary Churn):** Khách hàng tự quyết định ngừng sử dụng dịch vụ hoặc chuyển sang đối thủ do không hài lòng về chất lượng, giá cả hoặc trải nghiệm.
- **Churn thụ động (Involuntary Churn):** Khách hàng ngừng sử dụng do các nguyên nhân ngoài ý muốn như lỗi thanh toán, thẻ hết hạn hoặc thay đổi điều kiện sử dụng dịch vụ.

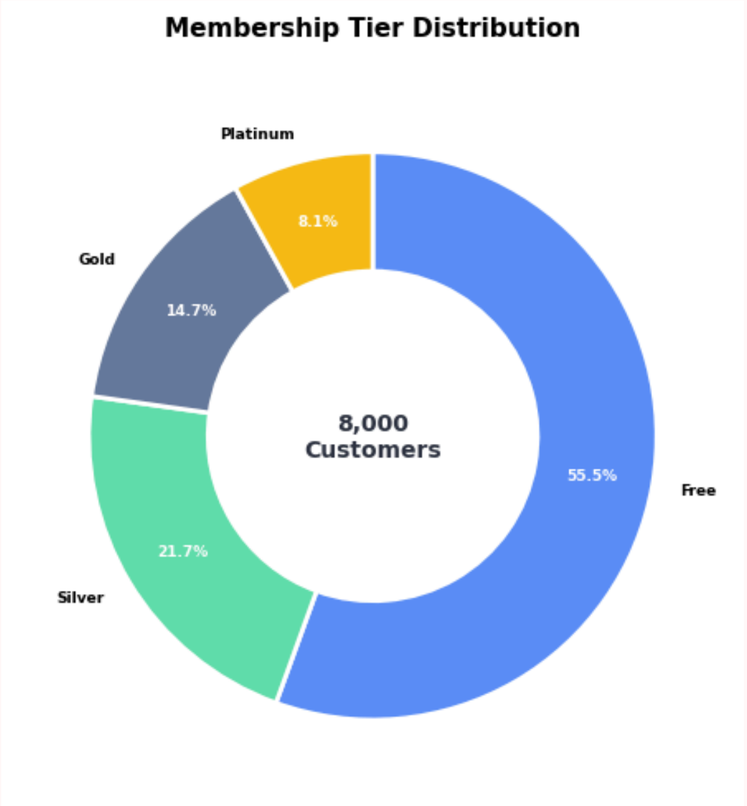
Mô hình học máy áp dụng gồm:

- Logistic Regression
- Decision Tree
- Random Forest
- Multi-Layer Perceptron (MLP)

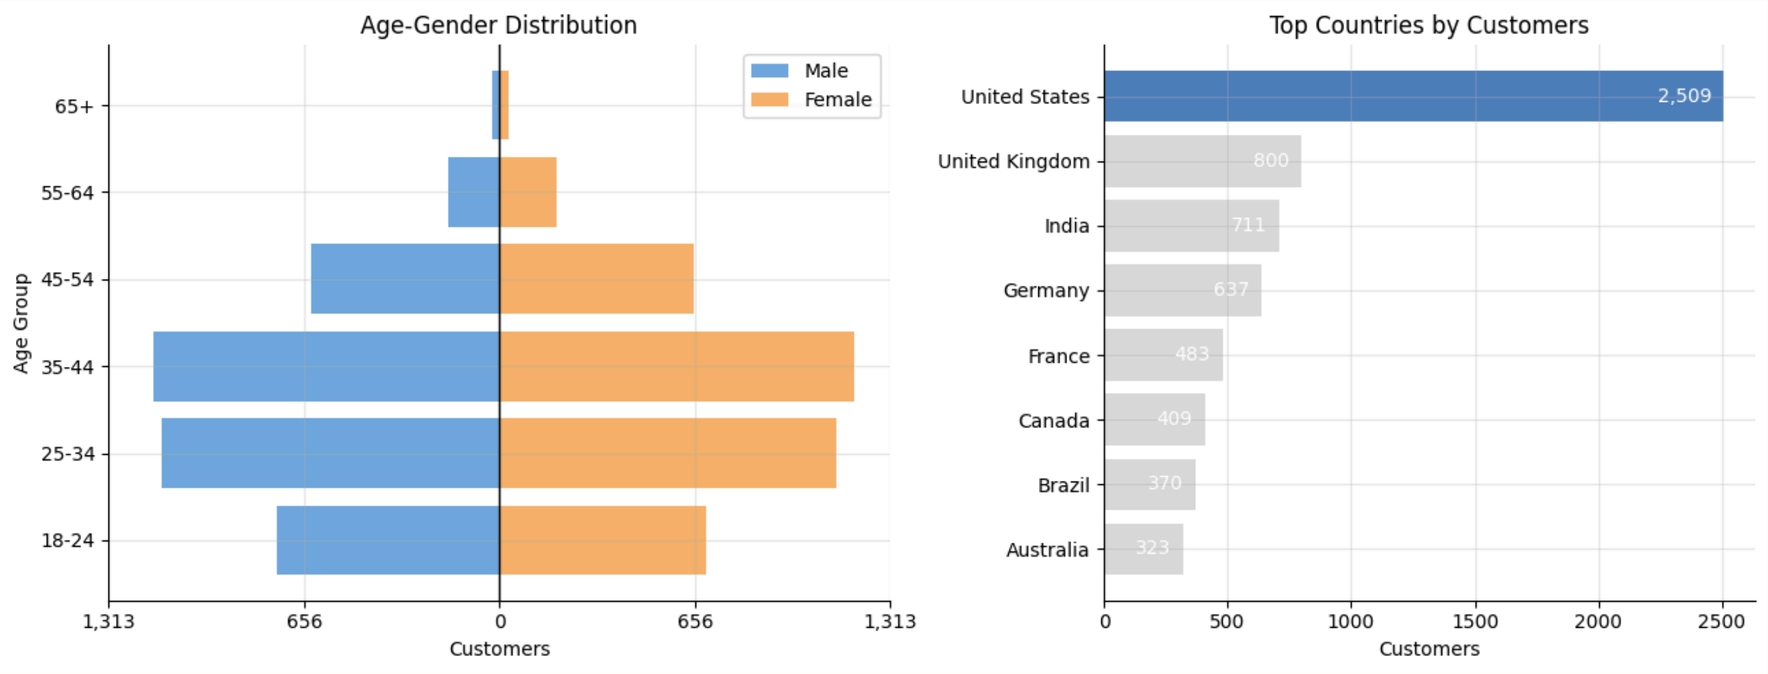
Các mô hình được huấn luyện và đánh giá trên bộ dữ liệu khách hàng nhằm dự đoán khả năng khách hàng rời bỏ dịch vụ (Churn).

KHÁM PHÁ DỮ LIỆU

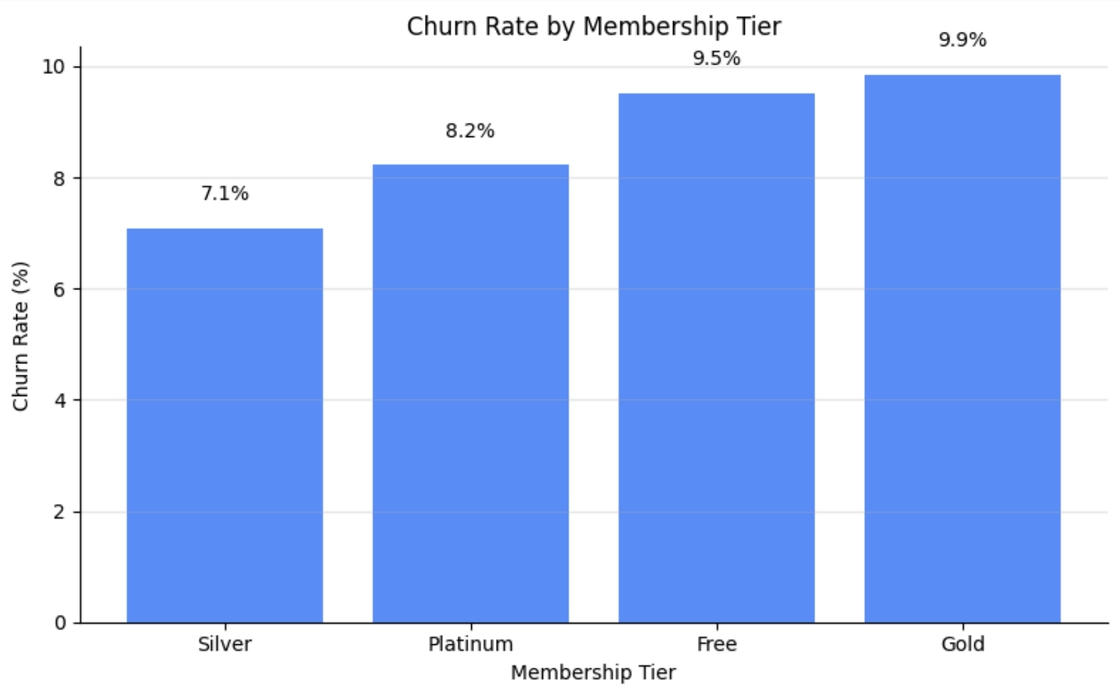


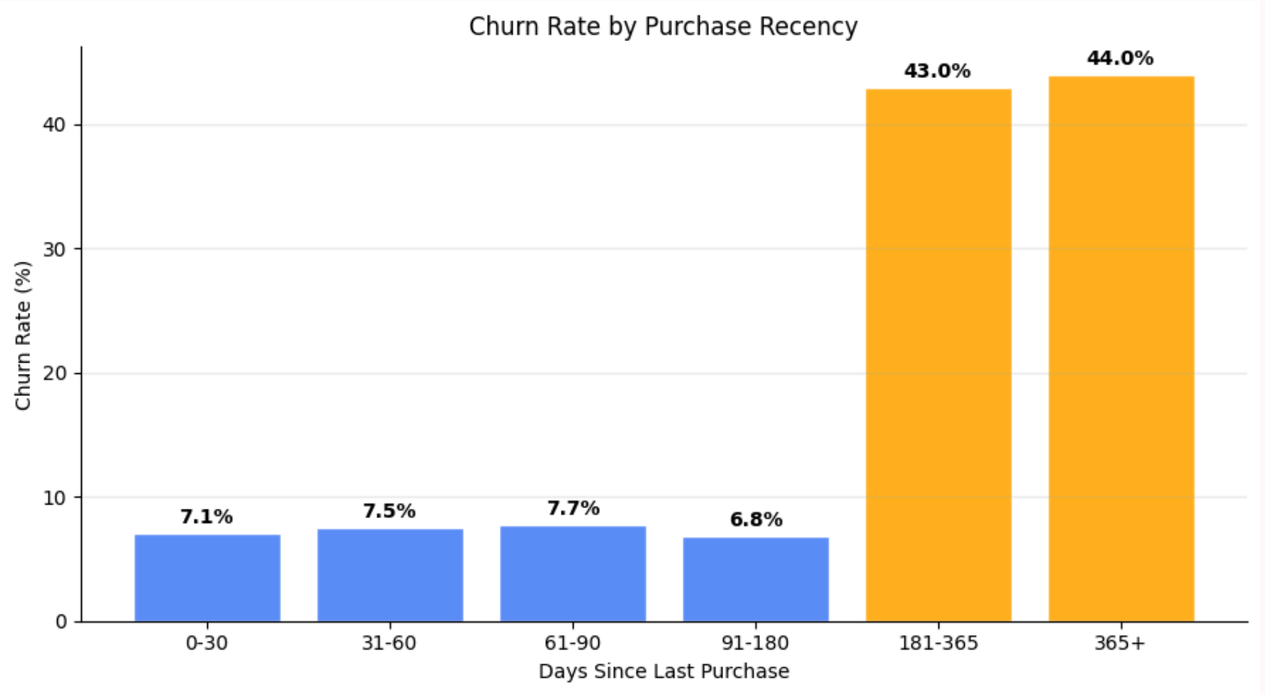


KHÁM PHÁ DỮ LIỆU

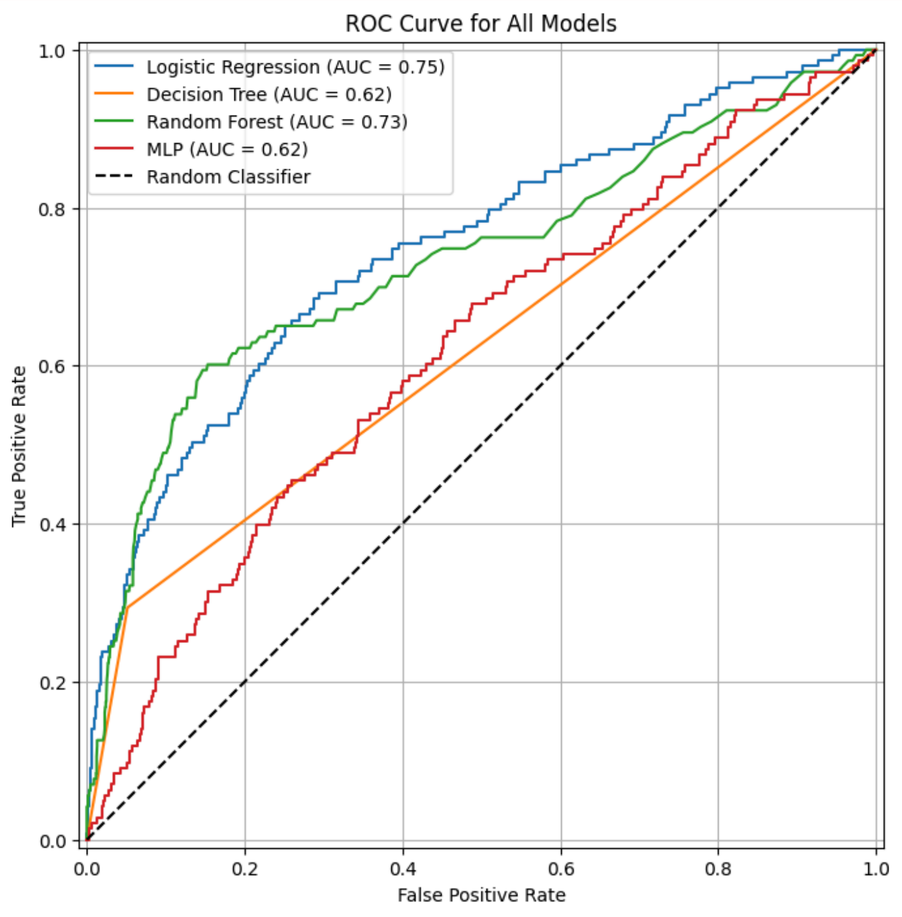


KHÁM PHÁ DỮ LIỆU





KẾT QUẢ MÔ HÌNH



Nhận xét:

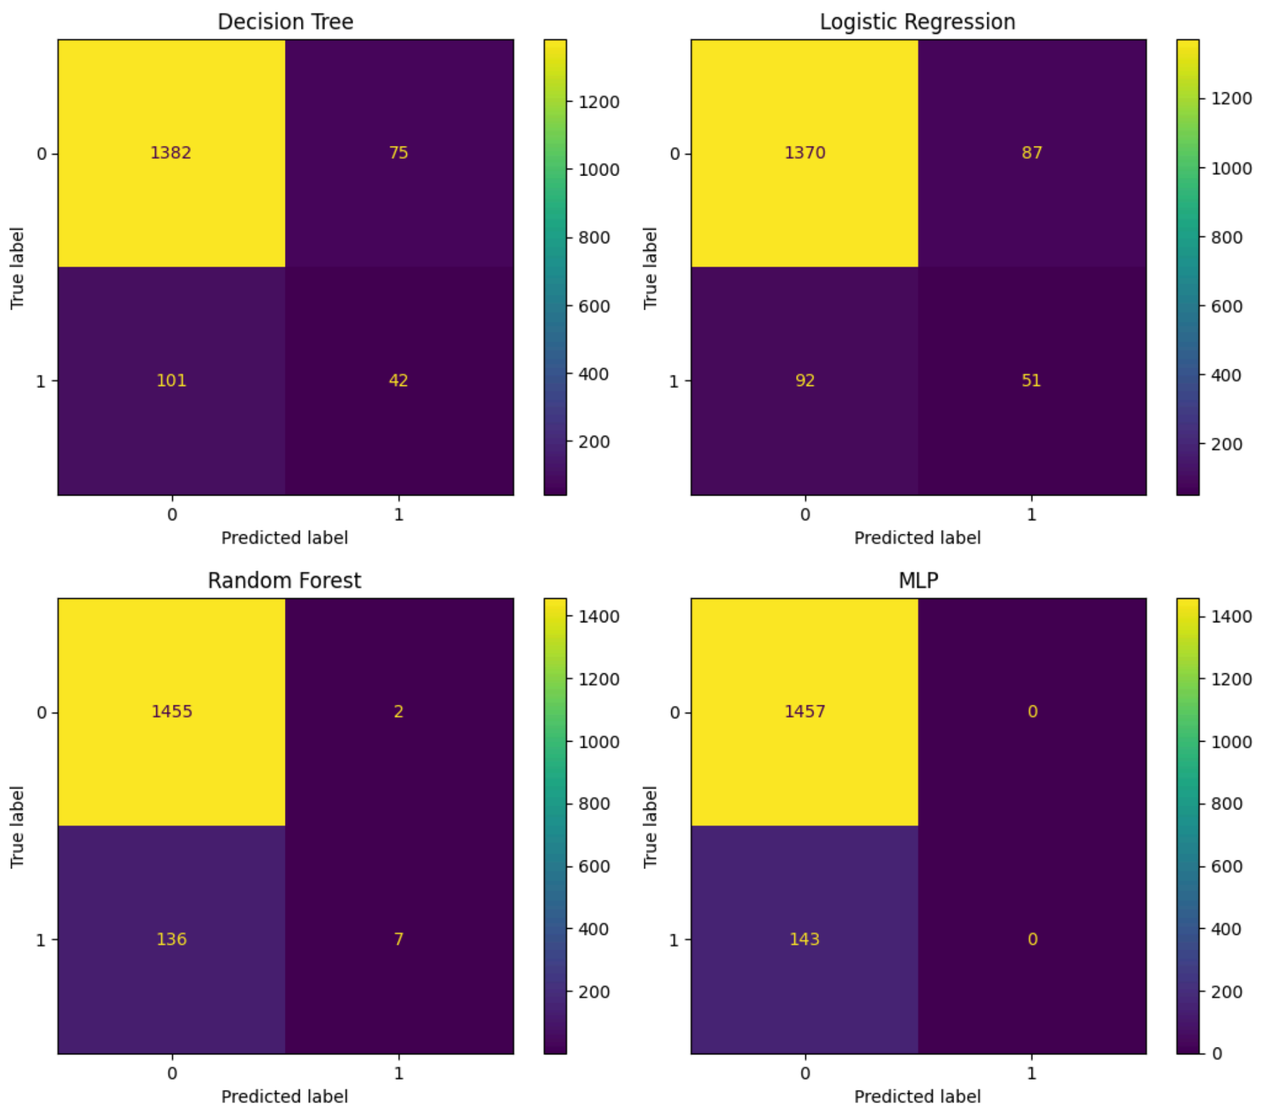
Biểu đồ ROC cho thấy một sự phân hóa năng lực rất rõ rệt giữa các thuật toán: Logistic Regression xuất sắc dẫn đầu với điểm AUC cao nhất, theo sau sát sao bởi Random Forest – mô hình này thậm chí còn vượt trội hơn ở giai đoạn đầu đồ thị nhờ khả năng kiểm soát tỷ lệ báo động giả cực tốt. Trong khi đó, Decision Tree và MLP tỏ ra khá hụt hơi khi dậm chân tại chỗ ở mức AUC khiêm tốn là 0.62, chưa kể đường cong gập ghềnh của MLP cho thấy các mức xác suất dự đoán của mạng thần kinh này vẫn chưa thực sự ổn định. Tóm lại, đồ thị này là minh chứng rõ ràng để bạn tự tin chọn Logistic Regression hoặc Random Forest làm giải pháp phân loại tối ưu cho bài toán, đồng thời có thể tạm loại bỏ hai mô hình còn lại để đỡ tốn tài nguyên tối ưu hó

KẾT QUẢ MÔ HÌNH

```
Train: (6400, 22)
Test : (1600, 22)
```

	Model	Accuracy	Precision	Recall	F1
2	Random Forest	0.910469	0.408701	0.031457	0.058254
0	Logistic Regression	0.877812	0.313543	0.305934	0.308707
3	MLP	0.910625	0.375000	0.010481	0.020101
1	Decision Tree	0.893594	0.360610	0.242960	0.289097

KẾT QUẢ PHÂN LOẠI



Nhận xét:

- MLP: Mô hình không nhận diện được các mẫu thuộc lớp 1, khi toàn bộ 143 mẫu của lớp này đều được dự đoán là lớp 0.
- Random Forest: Mô hình đạt độ chính xác tổng thể cao nhờ dự đoán đúng phần lớn các mẫu lớp 0, tuy nhiên chỉ nhận diện đúng 7 trong số 143 mẫu thuộc lớp 1.
- Decision Tree và Logistic Regression: Hai mô hình cho thấy khả năng nhận diện lớp 1 tốt hơn so với MLP và Random Forest. Trong đó, Logistic Regression đạt kết quả nổi bật nhất khi dự đoán đúng 51 mẫu lớp 1. Tuy nhiên, hiệu quả này đi kèm với việc số lượng mẫu lớp 0 bị phân loại nhầm tăng lên (87 mẫu).

TỔNG QUÁT VỀ BÀI TOÁN VÀ DỮ LIỆU

Bài toán: Phân tích và dự báo doanh thu thương mại điện tử theo tuần bằng ARIMA, SARIMA và Holt-Winters

Bộ dữ liệu

- Tên bộ dữ liệu: E-Commerce Customer Behavior & Sales 2020–2026
- File sử dụng: orders.csv
- Quy mô dữ liệu: 25.000 đơn hàng

Tiền xử lý:

- Chuyển đổi order_date sang định dạng thời gian.
- Sắp xếp dữ liệu theo thứ tự thời gian.
- Chọn total_amount_usd làm biến doanh thu.
- Tổng hợp doanh thu theo tuần.
- Thu được chuỗi doanh thu gồm 326 quan sát từ năm 2020–2026.
- Biến mục tiêu weekly_revenue = tổng total_amount_usd theo từng tuần

Mô hình dự đoán:

- ARIMA
- SARIMA
- Holt-Winters

Chỉ số đánh giá:

- RMSE
- MAPE
- MAE

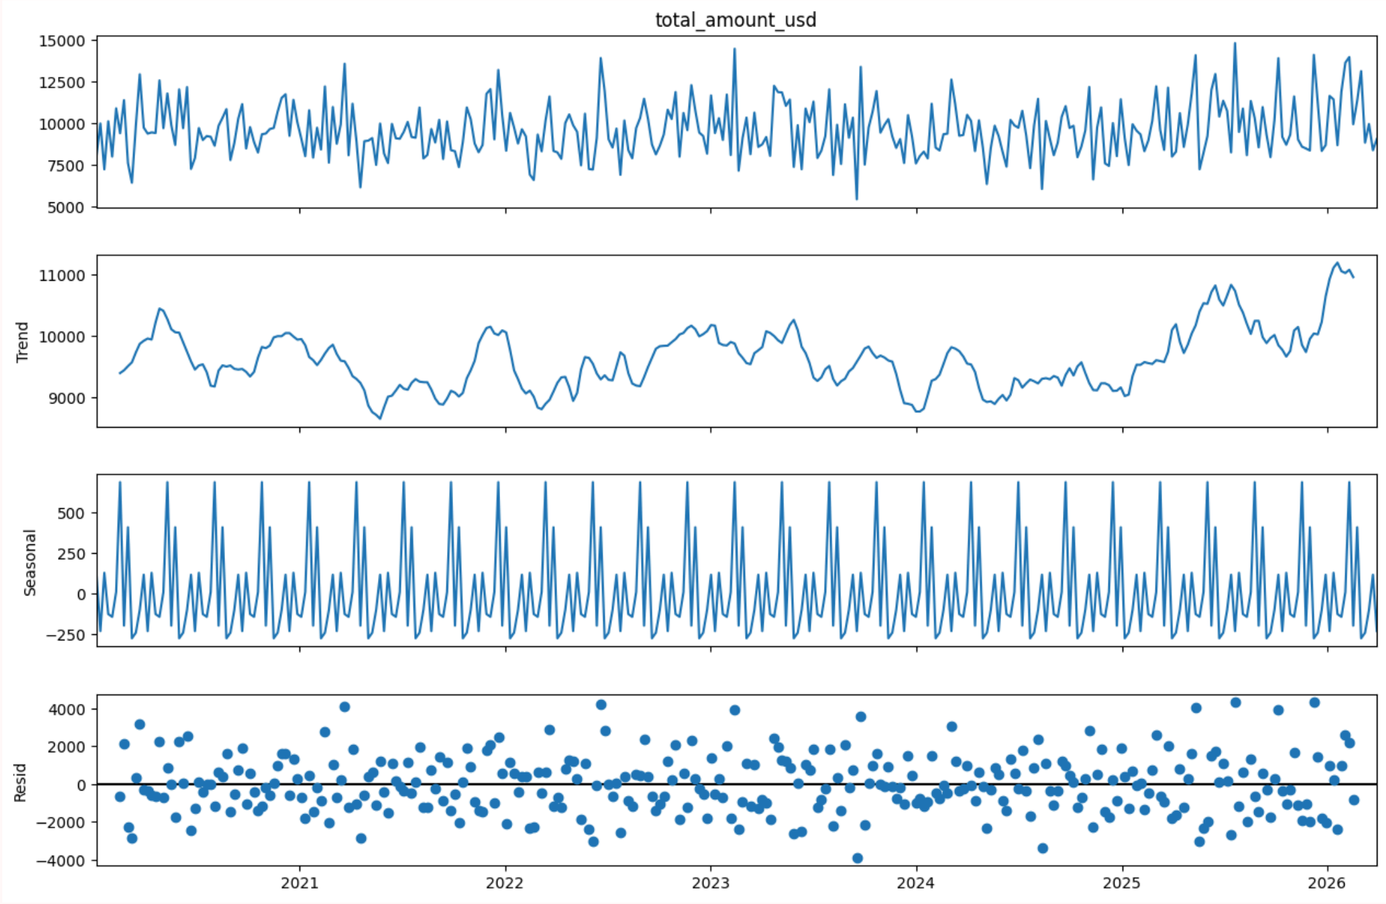
PHÂN TÍCH CHUỖI THỜI GIAN VÀ KIỂM ĐỊNH TÍNH DỪNG

Kết quả phân tích dữ liệu:

- Chuỗi dữ liệu gồm 326 tuần liên tiếp từ năm 2020 đến năm 2026.
- Doanh thu trung bình: 9.620,87 USD/tuần.
- Doanh thu thấp nhất: 5.433,90 USD.
- Doanh thu cao nhất: 14.815,12 USD.
- Đồ thị doanh thu xuất hiện các dao động lặp lại theo chu kỳ khoảng 12 tuần.

Phân rã chuỗi thời gian:

- Trend thể hiện xu hướng dài hạn.
- Seasonal cho thấy doanh thu lặp lại theo chu kỳ khoảng 12 tuần.
- Residual là phần nhiễu còn lại sau khi loại bỏ xu hướng và mùa vụ.



PHÂN TÍCH CHUỖI THỜI GIAN VÀ KIỂM ĐỊNH TÍNH DỪNG

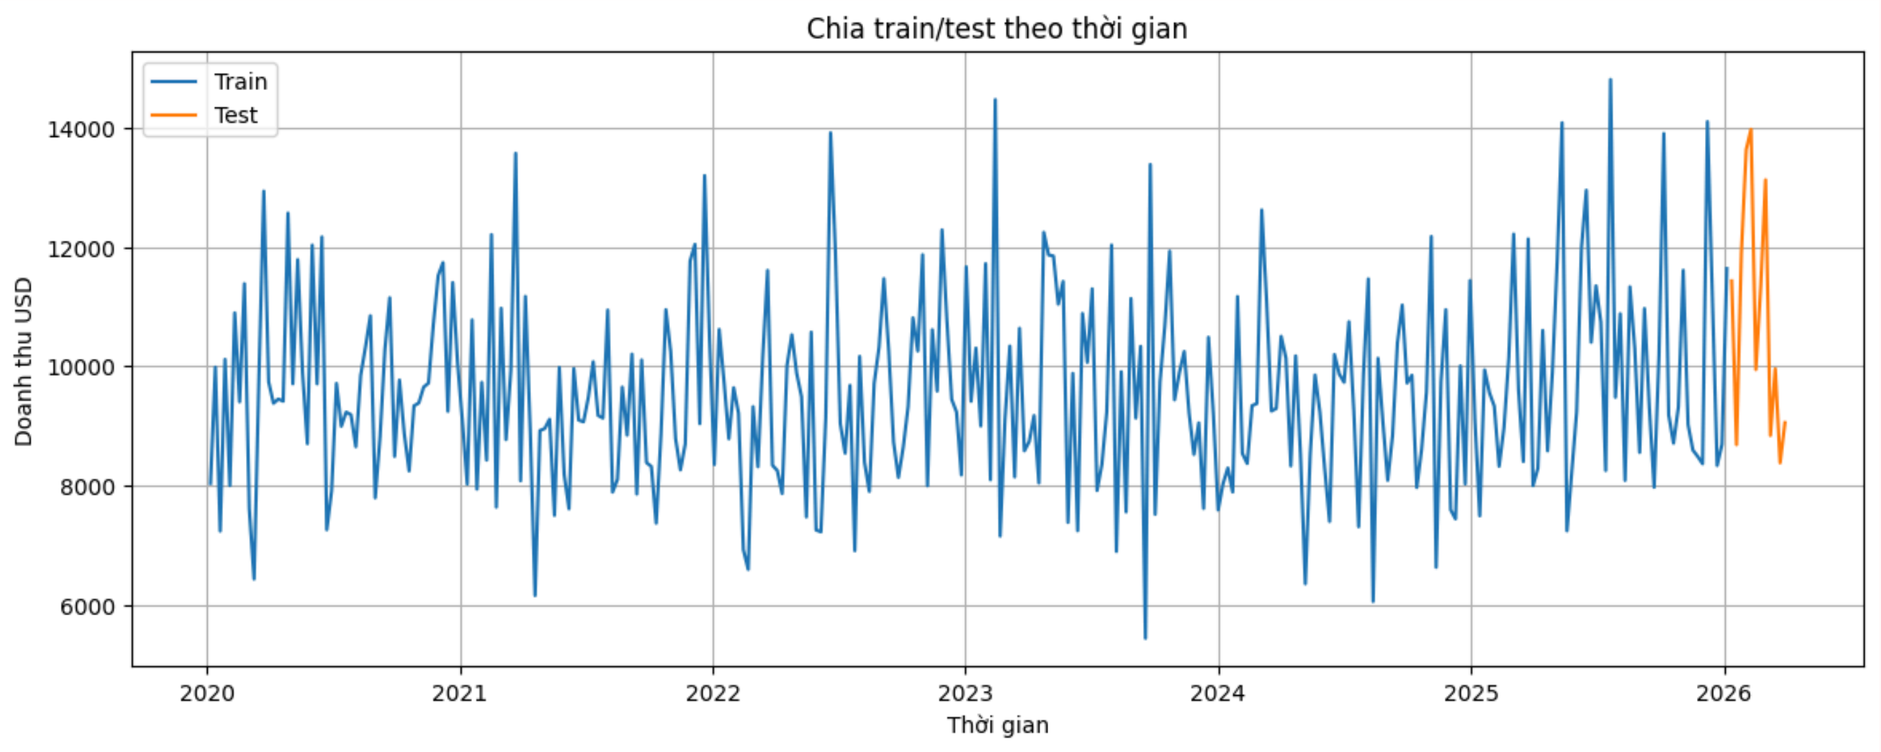
CHỈ SỐ	GIÁ TRỊ
ADF Statistic	-18.3437
p-value	2.24×10^{-30}
Critical Value (5%)	-2.8705

Nhận xét:

- p-value < 0,05.
- Chuỗi dữ liệu đạt tính dừng.
- Không cần thực hiện sai phân (d = 0).
- Dữ liệu đủ điều kiện để xây dựng mô hình dự báo.



CHIA TRAIN/TEST



- Train: 314 tuần, từ 06/01/2020 đến 05/01/2026
- Test: 12 tuần, từ 12/01/2026 đến 30/03/2026

KẾT QUẢ DỰ BÁO CỦA CÁC MÔ HÌNH

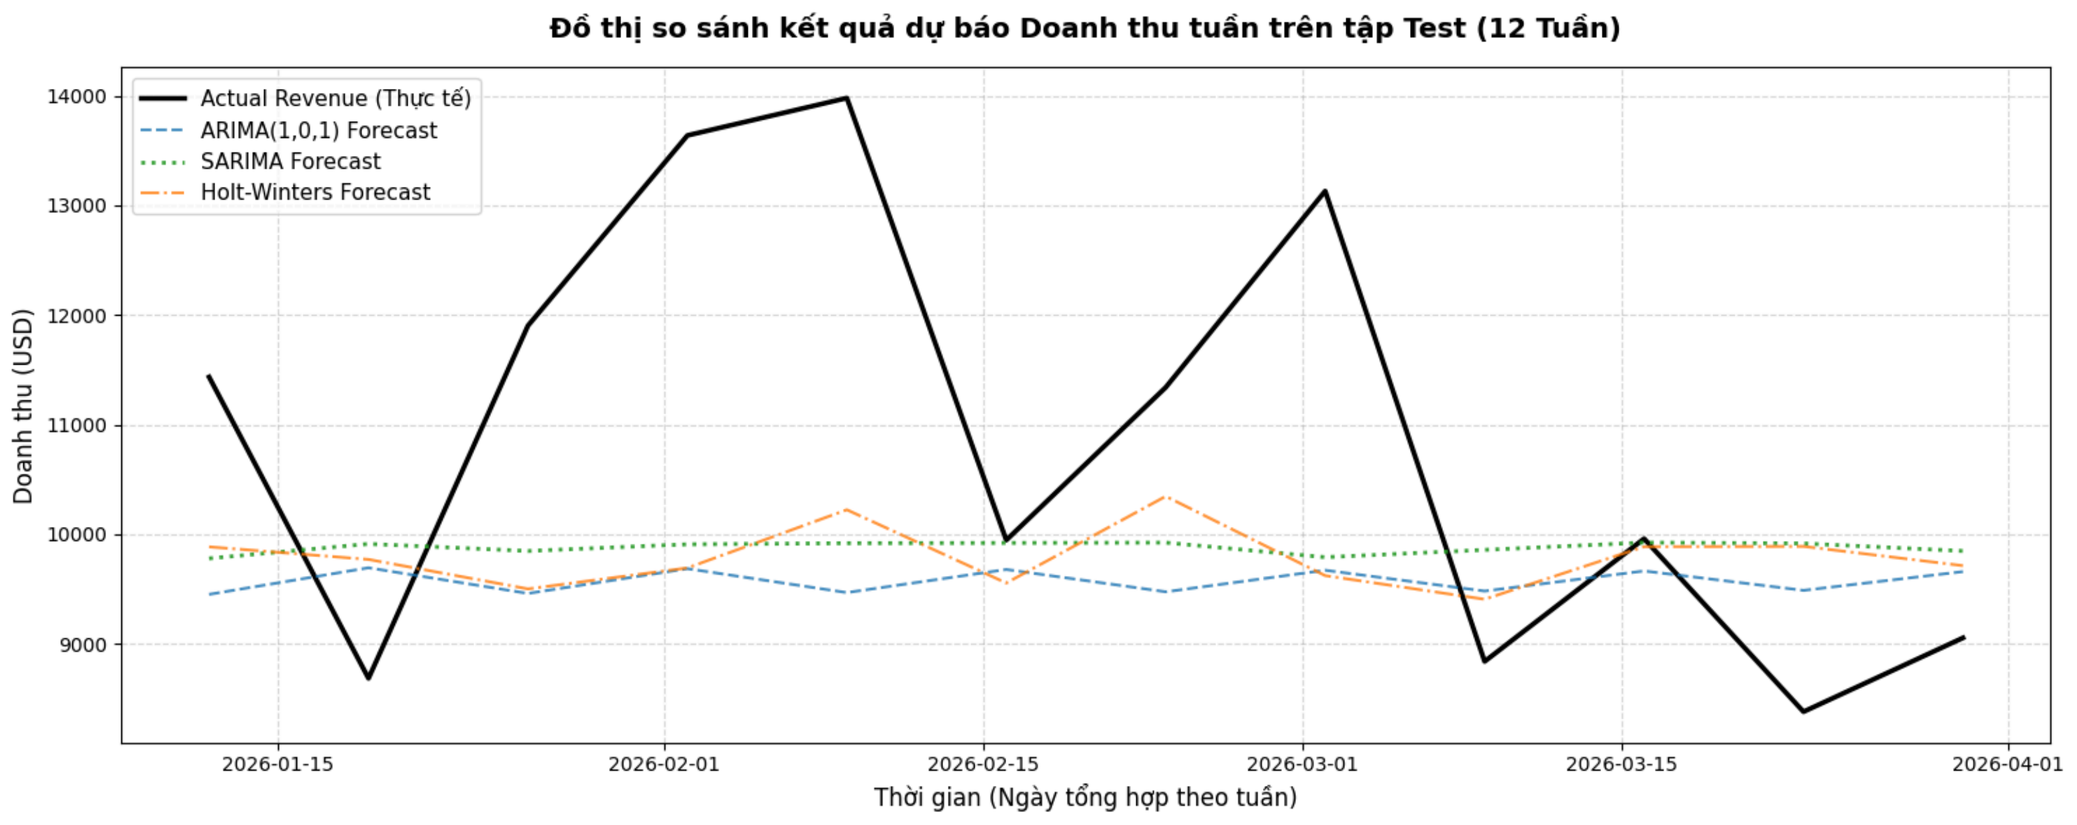
MÔ HÌNH	MAE	RMSE	MAPE
ARIMA(1,0,1)	1845.45	2319.13	15.53%
SARIMA$(1,1,1)(1,0,0)_{12}$	1651.42	2155.86	14.72%
Holt-Winters	1703.71	2151.42	14.49%



Nhận xét:

- ARIMA cho kết quả thấp nhất do chưa mô tả được yếu tố mùa vụ.
- SARIMA cải thiện độ chính xác nhờ bổ sung thành phần mùa vụ.
- Holt-Winters đạt MAPE thấp nhất trên tập kiểm tra.
- Cả ba mô hình đều dự báo được xu hướng chung của doanh thu tuần.
- Đường dự báo thường mượt hơn dữ liệu thực tế do các mô hình tập trung mô tả xu hướng và quy luật lặp lại của chuỗi.

KẾT QUẢ DỰ BÁO CỦA CÁC MÔ HÌNH



SO SÁNH MÔ HÌNH VÀ KẾT LUẬN

MÔ HÌNH	MAE	RMSE	MAPE (%)
Holt-Winters (Expanding Window)	1663.50	2077.31	14.27
ARIMA (Rolling Window)	1862.61	2352.88	15.67
ARIMA (Expanding Window)	1863.08	2349.77	15.67
SARIMA (Rolling Window)	1865.05	2190.82	16.49
SARIMA (Expanding Window)	1868.57	2191.56	16.55
Holt-Winters (Rolling Window)	1919.56	2239.88	17.19

CẢM ƠN THẦY
VÀ CÁC BẠN ĐÃ LẮNG NGHE

